

UNIVERSIDAD NACIONAL DE TRUJILLO

Facultad de Ingeniería

Escuela Profesional de Ingeniería de Sistemas

Modelo predictivo de precios de palta Hass para decisiones de siembra en La Libertad

PROYECTO DE TESIS

Autores

Peña Serrano Jefferson Miguel

Robles Perez Martin Aryan

Asesor

Ing. Mendoza Rivera Ricardo

Línea de investigación

Gestión de desarrollo de software

Trujillo – Perú

2026

JURADO DICTAMINADOR

Presidente

(Grado académico) (Nombres y Apellidos)

Secretario

(Grado académico) (Nombres y Apellidos)

Vocal

(Grado académico) (Nombres y Apellidos)

Índice general

1	INTRODUCCIÓN	1
2	MÉTODO	7
2.1	Tipo de investigación	7
2.1.1	De acuerdo con la orientación o finalidad	7
2.1.2	De acuerdo con la técnica de contrastación	7
2.2	Clasificación del diseño de estudio	7
2.3	Diseño de investigación	8
2.4	Población, muestra y muestreo	9
2.4.1	Población	9
2.4.2	Muestra	9
2.4.3	Muestreo	9
2.5	Variables	10
2.5.1	Tipo	10
2.5.2	Operacionalización	11
2.6	Técnicas e instrumentos, validación y confiabilidad	12
2.6.1	Técnicas e instrumentos	12
2.6.2	Validación y confiabilidad	12
2.7	Método de análisis de datos	13
2.8	Procedimiento	14
2.9	Consideraciones éticas	15
3	ASPECTOS ADMINISTRATIVOS	16
3.1	Recursos y presupuesto	16
3.1.1	Recursos	16
3.1.2	Presupuesto	18
3.2	Financiamiento	18
3.2.1	De fuentes externas	18
3.2.2	Autofinanciación	19
3.3	Cronograma de ejecución	19
3.3.1	Período	19
3.3.2	Cronograma	19
4	RESULTADOS PRELIMINARES DEL ENTRENAMIENTO	20
4.1	Conjuntos de datos obtenidos	20
4.2	Predicción del precio FOB a seis semanas	20
4.3	Estimación del margen exportador	22
4.4	Clasificación del riesgo de margen bajo	23
4.5	Síntesis y limitaciones de los resultados	24

A	Matriz de operacionalización de variables	26
B	Matriz de consistencia	27
C	Diagrama de Ishikawa	28
D	Árbol de problemas	29
E	Árbol de objetivos	30
F	Instrumentos de recolección de datos	31
F.1	Cuestionario de apoyo a la decisión (pretest y posttest)	31
F.2	Ficha de extracción de datos (Aduanet / INEI)	32
F.3	Consentimiento informado abreviado	32
G	Constancia de aplicación de instrumentos	33

Índice de tablas

2.1	Diseño del componente predictivo	8
2.2	Variables analíticas y fuente prevista	11
2.3	Técnicas e instrumentos del estudio	12
3.1	Personal del proyecto	16
3.2	Presupuesto de bienes	17
3.3	Presupuesto de viajes y movilidad	17
3.4	Presupuesto de servicios	17
3.5	Presupuesto de recursos tecnológicos	18
3.6	Presupuesto consolidado del proyecto	18
3.7	Distribución del financiamiento	19
3.8	Cronograma de ejecución del proyecto	19
4.1	Métricas de los modelos de precio FOB	20
4.2	Métricas de los modelos de margen	22
4.3	Métricas de los modelos de riesgo	23
A.1	Matriz de operacionalización de variables	26
B.1	Matriz de consistencia del proyecto	27

Índice de figuras

2.1	Procedimiento de la investigación basado en CRISP-DM	15
4.1	Comparación del error absoluto medio de los modelos de regresión	21
4.2	Resultados de HistGradientBoosting para precio FOB	21
4.3	Resultados de Random Forest para el margen exportador	22
4.4	Comparación de modelos de riesgo de margen bajo	23
4.5	Matriz de confusión y curva ROC de la regresión logística	24
C.1	Diagrama de Ishikawa: causas de la decisión de siembra sin información anticipada	28
D.1	Árbol de problemas: decisión de siembra de palta Hass en La Libertad . .	29
E.1	Árbol de objetivos: modelo predictivo para apoyo a la decisión de siembra	30

CAPÍTULO 1: INTRODUCCIÓN

La palta Hass se ha consolidado como un producto agrícola de alto valor comercial por el crecimiento de su consumo en Norteamérica, Europa y Asia. Sin embargo, su precio de exportación presenta variaciones asociadas con la estacionalidad de las cosechas, la oferta de los países competidores, el destino comercial, el volumen disponible y los costos logísticos. Estas fluctuaciones afectan la estabilidad económica de productores y exportadores, porque una campaña con mayor producción no garantiza necesariamente un mejor margen cuando varios orígenes concentran su oferta en una misma ventana comercial (Asociación de Exportadores del Perú, 2023; Velásquez et al., 2025; Zhang et al., 2025).

La literatura reciente muestra que los métodos de inteligencia artificial y series temporales pueden contribuir a anticipar el comportamiento de los precios agrícolas. Zhang et al. (2025) aplicaron una arquitectura híbrida TCN–MLP–Attention a precios de palta y reportaron mejoras frente a modelos convencionales. Chen et al. (2023) combinaron descomposición de señales y redes LSTM para representar patrones no lineales, mientras que Xia (2024) comparó ARIMA y LSTM y concluyó que el desempeño depende de la estructura, longitud y variabilidad de la serie. En conjunto, estos antecedentes sustentan la conveniencia de comparar modelos estadísticos, aprendizaje automático y aprendizaje profundo, en vez de asumir anticipadamente que una sola familia de algoritmos será superior.

En América Latina persisten brechas de digitalización y acceso a inteligencia de mercados en el sector agrícola. Los pequeños y medianos productores suelen recibir información fragmentada, tardía o condicionada por intermediarios, lo que dificulta relacionar el precio internacional con sus propios costos y rendimientos. En el caso peruano, la expansión de las exportaciones de palta ha coexistido con periodos de sobreoferta, presión sobre los precios y mayores costos logísticos. Capuñay et al. (2025) describen el efecto de estas condiciones sobre la rentabilidad de las exportaciones peruanas entre 2018 y 2022, y Pantaleón et al. (2024) señalan que el crecimiento exportador no elimina

la fragilidad empresarial del sector.

La Libertad constituye un ámbito relevante para esta investigación por su actividad agroexportadora y por la presencia de productores vinculados con los valles de Chao, Virú, Moche y el área de influencia de Chavimochic. El conocimiento agronómico y la experiencia de campo son indispensables, pero no permiten por sí solos procesar miles de operaciones de exportación, reconocer ciclos de precios o evaluar simultáneamente escenarios de costo, productividad y volumen. El documento técnico que sirve de base al presente proyecto identifica precisamente tres necesidades del negocio: reducir el riesgo de pérdida económica por campaña, reducir la incertidumbre mediante pronósticos de precios FOB y reducir la desinformación mediante el análisis de ciclos históricos.

La realidad problemática se concentra, por tanto, en que las decisiones de siembra, ampliación o reducción de área se adoptan frecuentemente a partir de experiencia previa y precios observados, sin una herramienta que integre datos históricos reales de exportación, costos productivos y escenarios económicos. Cuando el productor toma como referencia un precio reciente sin considerar estacionalidad, destino, volumen exportado o costos, puede sobreestimar el ingreso de la campaña. Esta limitación adquiere mayor importancia en un cultivo cuyo resultado económico depende tanto del mercado internacional como de condiciones productivas locales.

El proyecto utilizará como fuentes principales la Encuesta Nacional Agropecuaria del Instituto Nacional de Estadística e Informática (INEI) y los registros de Aduanet correspondientes a la subpartida nacional 0804400000. El documento base registra una disponibilidad aproximada de 5 607 observaciones anuales en la fuente agropecuaria y 128 222 registros aduaneros antes de aplicar filtros de calidad y pertinencia. Estas cantidades representan el universo disponible de registros de origen, no el tamaño definitivo del conjunto analítico. El número final se determinará después de eliminar duplicados, tratar valores ausentes, validar dominios y conservar únicamente operaciones y unidades relacionadas con el alcance de la investigación.

De Aduanet se obtendrán la fecha de operación, país de destino, valor FOB y peso neto exportado. El precio FOB unitario no se tomará directamente como un valor aislado,

sino que se calculará como la relación entre el valor FOB y el peso neto válido de cada operación, para luego agregarse por semana o mes según el análisis. Del INEI se utilizarán variables de costos agrícolas, superficie, producción y cantidades equivalentes, entre ellas los campos P235_VAL, P237_VAL, P239, P241, P219_CANT_1, P219_CANT_2 y P219_EQUIV_KG, siempre que la documentación de cada encuesta confirme su correspondencia y unidad de medida. Kaggle podrá emplearse únicamente como fuente exploratoria o de contraste; no sustituirá los registros FOB peruanos.

Las variables del negocio se organizan alrededor de precio FOB por kilogramo, volumen exportado, fecha, temporada, destino, costos de producción, flete, hectáreas, productividad, margen y ganancia esperada. Las variables calculadas deberán conservar trazabilidad respecto de sus campos de origen. En particular, el margen se calculará a partir de ingresos y costos estimados, la productividad relacionará producción válida con superficie y los escenarios se construirán sobre distribuciones históricas del precio, evitando rangos arbitrarios que no estén respaldados por los datos procesados.

La solución se compone de cinco funciones analíticas principales. La primera es un módulo de cálculo de rentabilidad que integra costo de producción, precio FOB proyectado y productividad. La segunda es un simulador de escenarios optimista, esperado y pesimista que estima resultados económicos y apoya recomendaciones como sembrar, mantener, reducir área o esperar. La tercera es el modelo predictivo de precios FOB. La cuarta es un módulo interactivo para visualizar precios históricos por fecha y destino. La quinta genera reportes de ciclos, picos, caídas y comparaciones entre campañas.

La implementación preliminar compara cuatro enfoques para cada solución. Para precio FOB y margen se utilizaron Random Forest, HistGradientBoosting, ElasticNet y Prophet. Para la clasificación de riesgo se utilizaron Random Forest, HistGradientBoosting, regresión logística y Prophet adaptado como estimador continuo con umbral de clasificación. Esta combinación permite contrastar ensambles no lineales, un modelo regularizado interpretable y una referencia temporal. Los modelos FOB se entrenan y evalúan con un corte cronológico común, sin mezclar observaciones futuras con el conjunto de entrenamiento.

La evaluación predictiva empleará MAE, RMSE, MAPE y R^2 . El MAE permitirá interpretar el error promedio en la unidad del precio; el RMSE penalizará con mayor intensidad los errores grandes; y el MAPE facilitará una lectura porcentual, siempre que se controlen valores cercanos a cero. El entrenamiento preliminar se concentrará en un horizonte de seis semanas, mientras que los reportes históricos podrán presentar agregaciones mensuales.

Para el desarrollo de la solución tecnológica se consideraron tres metodologías estándar. KDD organiza el descubrimiento de conocimiento mediante selección, preprocesamiento, transformación, minería e interpretación; resulta útil para explicar la obtención de patrones, pero ofrece menor detalle para el despliegue y la retroalimentación del negocio. SEMMA estructura el trabajo en muestreo, exploración, modificación, modelado y evaluación; es adecuada para el tratamiento analítico, aunque se concentra principalmente en el proceso de modelado. CRISP-DM comprende entendimiento del negocio, entendimiento de los datos, preparación, modelado, evaluación y despliegue. Se selecciona CRISP-DM porque conecta de forma explícita las necesidades del productor con la preparación de fuentes heterogéneas, la comparación de algoritmos y la implementación de la aplicación.

La arquitectura propuesta separará la adquisición y preparación de datos, los servicios analíticos y la interfaz de usuario. El backend se desarrollará con Python y FastAPI para exponer servicios de consulta histórica, inferencia, simulación y generación de reportes. La aplicación cliente se implementará con tecnología React para entorno web adaptable o React Native si las pruebas de despliegue confirman su conveniencia móvil. La base de datos almacenará usuarios, series procesadas, ejecuciones de modelos y escenarios, procurando no conservar información personal que no sea necesaria para la investigación.

La investigación se justifica por su conveniencia, porque integra información que actualmente se consulta de forma separada; por su relevancia social, porque acerca analítica de mercado a productores con menor capacidad tecnológica; por sus implicaciones prácticas, porque traduce un pronóstico en margen y recomendaciones; por su valor teó-

rico, porque compara tres enfoques bajo un mismo conjunto temporal peruano; y por su utilidad metodológica, porque documenta un flujo reproducible de extracción, validación, modelado y evaluación.

En consecuencia, el problema de investigación se formula mediante la siguiente pregunta: ¿En qué medida el desarrollo de un modelo predictivo de precios de exportación de palta Hass, integrado con módulos de rentabilidad y análisis histórico, apoyará la toma de decisiones de siembra de productores agrícolas de La Libertad, Perú?

La hipótesis general plantea que el desarrollo del modelo predictivo de precios de exportación de palta Hass, integrado con módulos de rentabilidad, escenarios y análisis histórico, mejorará el apoyo a la toma de decisiones de siembra de productores agrícolas de La Libertad. Las subhipótesis establecen que: el módulo de rentabilidad mejorará la estimación del margen esperado; el simulador reducirá la incertidumbre percibida al comparar escenarios; el modelo seleccionado alcanzará menor error que las alternativas comparadas; el análisis histórico facilitará la identificación de tendencias y estacionalidad; y los reportes de ciclos mejorarán la interpretación de periodos favorables y desfavorables.

El objetivo general es desarrollar un modelo predictivo de precios de exportación de palta Hass, integrado en una herramienta de apoyo a la toma de decisiones de siembra para productores agrícolas de La Libertad. Los objetivos específicos son: caracterizar y depurar los datos de Aduanet e INEI relacionados con precio, volumen, destino, producción y costos; construir variables temporales y económicas con trazabilidad; implementar y comparar algoritmos de regresión y pronóstico para un horizonte de seis semanas; desarrollar los módulos de rentabilidad, escenarios, análisis histórico y reportes; y evaluar la precisión del modelo y la utilidad de la herramienta con usuarios del ámbito productivo.

El estudio se limitará espacialmente a la aplicación del problema en productores de palta Hass de La Libertad y utilizará información nacional de exportación y producción que permita contextualizar dicho ámbito. Temporalmente, procesará los registros disponibles y verificables comprendidos entre 2018 y el último periodo completo accesible al momento de cerrar la base. No se afirmará que el sistema predice el precio recibido in-

dividualmente por cada productor, pues el valor FOB agregado puede diferir del precio en chacra por contratos, calidad, calibre, intermediación y logística. Tampoco se presentarán como resultados ejecutados las evaluaciones de usuarios o métricas de modelos que todavía correspondan a actividades futuras del proyecto.

CAPÍTULO 2: MÉTODO

2.1 Tipo de investigación

2.1.1 De acuerdo con la orientación o finalidad

La investigación es **aplicada**, porque utiliza técnicas de series temporales, aprendizaje automático y desarrollo de software para atender un problema concreto: la falta de información anticipada y contextualizada para evaluar decisiones de siembra de palta Hass en La Libertad. El producto será un modelo predictivo integrado con módulos de rentabilidad, escenarios y análisis histórico.

2.1.2 De acuerdo con la técnica de contrastación

La investigación es **explicativa**, debido a que evaluará el efecto del uso de la solución sobre indicadores de apoyo a la decisión, y **predictiva** en su componente tecnológico, porque estimará precios FOB a seis semanas. La contrastación técnica comparará Random Forest, HistGradientBoosting, ElasticNet y Prophet mediante MAE, RMSE, MAPE y R^2 .

2.2 Clasificación del diseño de estudio

El enfoque es predominantemente **cuantitativo**. La proyección temporal es **retrospectiva** para el entrenamiento con registros históricos y **prospectiva** para la evaluación de los pronósticos y de la utilidad del sistema. La frecuencia de medición es **longitudinal**, porque el precio y el volumen se observan de forma ordenada en el tiempo. El componente algorítmico es no experimental, dado que no se manipulan las operaciones históricas; el componente de evaluación con usuarios es preexperimental, con una medición inicial y otra posterior al uso del prototipo.

El alcance analítico es descriptivo, predictivo y prescriptivo. Es descriptivo al caracterizar tendencias, destinos, estacionalidad y ciclos; predictivo al estimar el precio FOB futuro; y prescriptivo al combinar pronósticos, costos y productividad para generar escenarios de decisión.

2.3 Diseño de investigación

El estudio integra dos diseños complementarios. Para el componente predictivo se utiliza un diseño longitudinal de series temporales con evaluación fuera de muestra. Los registros se ordenarán cronológicamente y se dividirán en entrenamiento, validación y prueba sin aleatorizar el tiempo. Todos los algoritmos utilizarán los mismos periodos y horizontes.

Datos válidos → entrenamiento → validación temporal → prueba futura → comparación

Tabla 2.1

Diseño del componente predictivo

Etapas	Aplicación en el estudio
Preparación	Cálculo del precio FOB unitario, agregación temporal, depuración de duplicados, tratamiento de nulos y construcción de rezagos.
Entrenamiento	Ajuste de Random Forest, HistGradientBoosting, ElasticNet y Prophet con el bloque histórico inicial.
Validación	Selección de hiperparámetros mediante ventanas temporales expansivas o deslizantes.
Prueba	Pronóstico de observaciones posteriores no utilizadas en el ajuste.
Comparación	Evaluación mediante MAE, RMSE, MAPE y R^2 sobre el mismo conjunto de prueba.

Para evaluar el apoyo a la decisión se aplicará un diseño preexperimental de un solo grupo:

$$G \rightarrow O_1 \rightarrow X \rightarrow O_2$$

donde G representa a los participantes de la prueba piloto; O_1 , la medición inicial

de comprensión, incertidumbre y forma de estimar rentabilidad; X , el uso guiado del prototipo; y O_2 , la medición posterior. Este diseño permitirá estimar cambios iniciales de utilidad percibida, pero no autoriza atribuir causalidad definitiva por la ausencia de un grupo de control.

2.4 Población, muestra y muestreo

2.4.1 Población

La población documental está constituida por los registros de la Encuesta Nacional Agropecuaria del INEI y las operaciones de Aduanet para la subpartida 0804400000 disponibles en el periodo de estudio. El documento técnico de base reporta aproximadamente 5 607 observaciones por año en la fuente agropecuaria y 128 222 registros aduaneros antes de la depuración. Estas cantidades son referencias del origen y no se asumirán como el número final de observaciones válidas.

La población usuaria está conformada por productores, asesores y técnicos vinculados con la producción de palta Hass en La Libertad que puedan utilizar información de precios, rentabilidad y ciclos para apoyar decisiones de campaña.

2.4.2 Muestra

En el componente documental se aplicará un criterio censal: se conservarán todos los registros que cumplan los criterios de inclusión y calidad. La muestra analítica definitiva se informará después del proceso ETL, junto con el número de registros excluidos y su causa.

Para la evaluación del instrumento y del prototipo se realizará una prueba piloto con un mínimo de 30 participantes, de acuerdo con la guía UNT-2026. Esta cantidad corresponde a una evaluación inicial de confiabilidad y usabilidad; no sustituye una muestra probabilística representativa de todos los productores de La Libertad.

2.4.3 Muestreo

El muestreo documental será no probabilístico por criterios y cobertura censal de los registros accesibles. Se incluirán operaciones con fecha válida, valor FOB positivo, peso

neto positivo, destino identificable y correspondencia con la subpartida seleccionada. Se excluirán duplicados, operaciones anuladas, valores imposibles y registros sin información suficiente para calcular el precio unitario.

La selección de participantes será no probabilística e intencional, considerando experiencia o participación en la cadena de palta Hass, disponibilidad para completar las dos mediciones y consentimiento informado. Se procurará incluir perfiles con diferentes tamaños de unidad productiva para ampliar la diversidad de la prueba piloto.

2.5 Variables

2.5.1 Tipo

La variable independiente es el **sistema predictivo de precios de exportación de palta Hass**, compuesto por los modelos de precio, margen y riesgo, el simulador de escenarios, el análisis histórico y los reportes de ciclos. La variable dependiente es el **apoyo a la toma de decisiones de siembra**, evaluado mediante precisión predictiva, comprensión de la información, reducción de incertidumbre y utilidad percibida.

Como variables de entrada se utilizarán fecha, valor FOB, peso neto, destino, temporada, costos agrícolas, superficie y producción. El precio FOB unitario, la productividad, el ingreso, el costo total, el margen y la ganancia serán variables calculadas y deberán conservar trazabilidad respecto de los campos originales.

Tabla 2.2

Variables analíticas y fuente prevista

Variable	Campo o cálculo	Fuente y uso
Precio FOB unitario	Valor FOB / peso neto	Aduanet; variable objetivo del pronóstico.
Volumen exportado	PESO_NETO	Aduanet; presión de oferta y agregación temporal.
Fecha y temporada	FECHA, semana, mes	Aduanet e INEI; orden temporal y estacionalidad.
Destino	PAIS_DESC	Aduanet; segmentación por mercado.
Costos agrícolas	P235_VAL, P237_VAL, P239, P241	INEI; estimación del costo productivo.
Producción	P219_CANT_1, P219_CANT_2, P219_EQUIV_KG	INEI; productividad y escenarios.
Margen y ganancia	Variables calculadas	Simulador; diferencia entre ingresos y costos.

2.5.2 Operacionalización

La matriz de operacionalización se presenta en el Anexo A. Allí se especifican las definiciones conceptual y operacional, dimensiones, indicadores y escalas de medición de las variables independiente y dependiente.

2.6 Técnicas e instrumentos, validación y confiabilidad

2.6.1 Técnicas e instrumentos

Tabla 2.3

Técnicas e instrumentos del estudio

Técnica	Instrumento	Fuente o aplicación
Análisis documental	Ficha de extracción y diccionario de datos	Microdatos INEI y operaciones Aduanet 0804400000.
Procesamiento de datos	Scripts reproducibles en Python	Limpieza, integración, agregación y creación de variables.
Modelado predictivo	Random Forest, HistGradientBoosting, ElasticNet, regresión logística y Prophet	Predicción FOB a seis semanas, margen y riesgo de margen bajo.
Evaluación técnica	Ficha de métricas	MAE, RMSE y MAPE por modelo y horizonte.
Encuesta	Cuestionario pretest–posttest	Participantes de la prueba piloto del prototipo.
Juicio de expertos	Ficha de validación de contenido	Especialistas en agricultura, datos y metodología.

2.6.2 Validación y confiabilidad

El cuestionario será revisado por al menos tres jueces especialistas. La validez de contenido se estimará mediante V de Aiken por ítem y para el instrumento total. Antes de la aplicación principal se realizará una prueba piloto con un mínimo de 30 participantes. La consistencia interna se calculará con alfa de Cronbach y, cuando sea posible, omega de McDonald.

La confiabilidad del componente de datos se sustentará en reglas reproducibles: unicidad por operación o clave compuesta, dominio de fechas y destinos, valor FOB y peso neto positivos, trazabilidad de transformaciones y registro de exclusiones. La confiabili-

dad predictiva se evaluará mediante particiones temporales, comparación con una línea base y repetición del proceso con parámetros documentados.

2.7 Método de análisis de datos

El análisis comenzará con la inspección de estructura, tipos de datos, duplicados, valores ausentes y rangos. En Aduanet, el precio unitario se calculará solo cuando el valor FOB y el peso neto sean positivos. Las operaciones se agregarán temporalmente utilizando promedios ponderados por peso neto. En INEI, cada campo se interpretará según su diccionario oficial antes de combinar costos, superficie y producción.

El análisis descriptivo incluirá conteos, media, mediana, desviación estándar, rango intercuartílico, evolución temporal y distribución por destino. La serie se examinará mediante gráficos, autocorrelación, descomposición estacional y pruebas de estacionariedad cuando correspondan.

Random Forest, HistGradientBoosting, ElasticNet y Prophet se compararán sobre los mismos bloques temporales para la predicción FOB. Se calcularán:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

El MAPE se interpretará únicamente en observaciones con valores reales suficientemente alejados de cero. Los resultados preliminares se presentan para un horizonte de seis semanas. Para comparar errores pareados de modelos se verificará la distribución de las diferencias mediante Shapiro–Wilk; se empleará t de Student pareada si se cumplen sus supuestos o Wilcoxon en caso contrario, con $\alpha = 0,05$.

En la evaluación con usuarios se resumirán las respuestas por dimensión y momento. La diferencia pretest–posttest se analizará con t pareada o Wilcoxon, según los supuestos. Se reportarán el estadístico, valor p , intervalo de confianza y tamaño del efecto. La significancia estadística se interpretará junto con la magnitud y la utilidad práctica,

evitando afirmar causalidad definitiva por tratarse de un diseño preexperimental.


2.8 Procedimiento

Se utilizará CRISP-DM porque relaciona las necesidades del negocio con la preparación de datos, el modelado, la evaluación y el despliegue. El procedimiento comprende las siguientes fases:

1. **Comprensión del negocio.** Precisar las necesidades de rentabilidad, pronóstico y análisis de ciclos; definir indicadores y criterios de aceptación con apoyo de especialistas del sector.
2. **Comprensión de los datos.** Descargar y documentar los microdatos INEI y las operaciones Aduanet de la subpartida 0804400000; identificar claves, unidades y cobertura temporal.
3. **Preparación.** Eliminar duplicados, validar dominios, tratar ausentes, calcular precio FOB unitario, agregar la serie y construir rezagos, temporada, productividad, costos y margen.
4. **Modelado.** Ajustar Random Forest, HistGradientBoosting, ElasticNet, regresión logística y Prophet mediante divisiones reproducibles y parámetros documentados.
5. **Evaluación.** Comparar MAE, RMSE y MAPE por horizonte; revisar residuos, estabilidad e interpretabilidad; seleccionar el modelo que supere la línea base con comportamiento consistente.
6. **Desarrollo.** Implementar servicios en FastAPI y una interfaz React o React Native con acceso, pronóstico, histórico, simulación, recomendación, reportes y notificaciones.
7. **Validación.** Validar instrumentos con jueces, ejecutar la prueba piloto, analizar confiabilidad y comparar las mediciones pretest y postest.
8. **Despliegue y documentación.** Preparar una versión de prueba y documentar código, diccionario de datos, parámetros, resultados y limitaciones.

Figura 2.1

Procedimiento de la investigación basado en CRISP-DM



2.9 Consideraciones éticas

La investigación respetará la integridad, trazabilidad y reproducibilidad de los datos. Se conservará el origen de cada campo y no se alterarán observaciones para favorecer el desempeño de un algoritmo. Toda exclusión se documentará mediante reglas previas y un reporte de calidad.

Los participantes recibirán información sobre el propósito, las actividades, el uso de sus respuestas y su derecho a retirarse sin consecuencia. Se solicitará consentimiento informado y se evitará recopilar datos personales que no sean necesarios. Los resultados se presentarán de forma agregada.

La herramienta será descrita como apoyo y no como garantía de rentabilidad. Las recomendaciones mostrarán sus supuestos, horizonte e incertidumbre, porque el precio FOB agregado no equivale necesariamente al precio recibido por un productor particular. También se respetarán las licencias, términos de uso y normas de citación de las fuentes, software y publicaciones.

CAPÍTULO 3: ASPECTOS ADMINISTRATIVOS

3.1 Recursos y presupuesto

Los recursos se organizan de acuerdo con las necesidades reales de extracción y procesamiento de datos, desarrollo del prototipo, validación de instrumentos y prueba piloto. Los equipos de cómputo y el trabajo de autores y asesor son aportes no monetarios; por ello se registran sin costo directo para el proyecto.

3.1.1 Recursos

Personal

Tabla 3.1

Personal del proyecto

Participante	Función	Costo (\$/)
Peña Serrano Jefferson Miguel	Extracción de datos, modelado, desarrollo y documentación.	0,00
Robles Perez Martin Ar-yan	Análisis, desarrollo, validación y documentación.	0,00
Ing. Mendoza Rivera Ricardo	Asesoría metodológica y técnica.	0,00

Bienes

Tabla 3.2

Presupuesto de bienes

Descripción	Cantidad	C.U. (S/)	Total (S/)
Papel bond A4	2	25,00	50,00
Carpetas para validación y consentimiento	5	4,00	20,00
Formatos impresos para piloto y jueces	40	1,00	40,00
Memorias USB para respaldo	2	35,00	70,00
Subtotal			180,00

Viajes

Tabla 3.3

Presupuesto de viajes y movilidad

Descripción	Cantidad	C.U. (S/)	Total (S/)
Movilidad local a zonas productivas de La Libertad	8	20,00	160,00
Alimentación y movilidad complementaria	4	60,00	240,00
Subtotal			400,00

Servicios

Tabla 3.4

Presupuesto de servicios

Descripción	Cantidad	C.U. (S/)	Total (S/)
Internet y telefonía	6 meses	60,00	360,00
Impresión y fotocopiado	1	150,00	150,00
Anillado o encuadernación	3	25,00	75,00
Subtotal			585,00

Tecnológicos

Tabla 3.5

Presupuesto de recursos tecnológicos

Descripción	Cantidad	C.U. (S/)	Total (S/)
Equipos portátiles de propiedad de los autores	2	0,00	0,00
Python, FastAPI, React y bibliotecas de código abierto	1	0,00	0,00
Servicio de despliegue de prueba	6 meses	50,00	300,00
Almacenamiento y copias de seguridad	6 meses	10,00	60,00
Subtotal			360,00

3.1.2 Presupuesto

Tabla 3.6

Presupuesto consolidado del proyecto

Rubro	Total (S/)
Personal	0,00
Bienes	180,00
Viajes y movilidad	400,00
Servicios	585,00
Tecnológicos	360,00
Total general	1 525,00

3.2 Financiamiento

3.2.1 De fuentes externas

No se ha confirmado financiamiento de instituciones públicas, empresas privadas ni cooperación externa. En consecuencia, el proyecto registra 0 % de financiamiento externo.

3.2.2 Autofinanciación

Los autores cubrirán el 100 % de los desembolsos previstos. La dedicación del personal, los equipos propios y el software de código abierto se consideran aportes no monetarios.

Tabla 3.7

Distribución del financiamiento

Fuente	Porcentaje	Monto (S/)
Fuentes externas	0 %	0,00
Autofinanciación	100 %	1 525,00
Total	100 %	1 525,00

3.3 Cronograma de ejecución

3.3.1 Período

El proyecto se ejecutará del 1 de julio al 31 de diciembre de 2026, con una dedicación estimada de 20 horas semanales por autor. Las fechas deberán ajustarse mediante adenda si la aprobación formal del proyecto ocurre después del inicio previsto.

3.3.2 Cronograma

Tabla 3.8

Cronograma de ejecución del proyecto

Actividad	Jul.	Ago.	Set.	Oct.	Nov.	Dic.
Validación de instrumentos por jueces	X					
Extracción y documentación de Aduanet e INEI	X	X				
Limpieza, integración y análisis exploratorio		X	X			
Entrenamiento y comparación de modelos			X	X		
Desarrollo de API y aplicación			X	X	X	
Prueba piloto y evaluación					X	
Análisis e interpretación de resultados					X	X
Redacción, revisión y entrega				X	X	X

CAPÍTULO 4: RESULTADOS PRELIMINARES DEL ENTRENAMIENTO

4.1 Conjuntos de datos obtenidos

La ejecución reproducible de los scripts generó tres conjuntos analíticos. El conjunto de predicción FOB contiene 2 312 observaciones válidas con precio objetivo localizado aproximadamente seis semanas después de cada observación inicial. Se reservaron cronológicamente 1 849 registros para entrenamiento y 463 para prueba. El conjunto de margen contiene 585 registros relacionados con mercado exterior; 438 se utilizaron para entrenamiento y 147 para prueba. El conjunto de escenarios contiene las mismas 585 observaciones, de las cuales 147 pertenecen al cuartil inferior del margen y fueron etiquetadas como riesgo de margen bajo.

La reducción del conjunto FOB respecto del archivo original se debe a que se eliminaron filas sin una observación futura dentro de una tolerancia de dos semanas alrededor del horizonte solicitado. Así se evita interpretar seis registros posteriores como si fueran necesariamente seis semanas.

4.2 Predicción del precio FOB a seis semanas

Tabla 4.1

Métricas de los modelos de precio FOB

Modelo	MAE	RMSE	MAPE (%)	R^2
Random Forest	0,321	0,425	19,482	0,247
HistGradientBoosting	0,319	0,426	19,001	0,245
ElasticNet	0,331	0,421	20,854	0,264
Prophet	0,438	0,538	23,358	-0,203

HistGradientBoosting obtuvo el menor MAE y MAPE, por lo que se selecciona preliminarmente cuando el criterio principal es reducir el error absoluto del precio. ElasticNet obtuvo el menor RMSE y el mayor R^2 , aunque su MAE fue superior. La diferencia pequeña entre los tres primeros modelos indica que la selección definitiva debe confirmarse me-

diante validación temporal por ventanas y comparación estadística de errores. Prophet presentó R^2 negativo y no superó una referencia basada en la media del conjunto de prueba.

Figura 4.1

Comparación del error absoluto medio de los modelos de regresión





Figura 4.2

Resultados de HistGradientBoosting para precio FOB



La dispersión de los puntos muestra que el modelo reproduce la tendencia general, pero comprime parte de los valores extremos. El histograma de residuos está centrado cerca de cero, aunque conserva colas asociadas con semanas de variación abrupta. En términos prácticos, un MAE de 0,319 USD/kg todavía es relevante para la estimación de rentabilidad y debe mostrarse como incertidumbre, no como un precio exacto garantizado.

4.3 Estimación del margen exportador

Tabla 4.2


Métricas de los modelos de margen

Modelo	MAE	RMSE	MAPE (%)	R^2
Random Forest	0,343	0,498	5,980	0,777
HistGradientBoosting	0,382	0,553	7,033	0,725
ElasticNet	0,392	0,553	7,094	0,724
Prophet	0,360	0,534	5,067	0,266

Random Forest presentó el mejor equilibrio entre MAE, RMSE y capacidad explicativa, con un R^2 de 0,777. Prophet alcanzó un MAPE menor, pero su R^2 fue 0,266 y utilizó una partición temporal distinta; por ello no debe declararse superior con base en una sola métrica. Para la primera versión del módulo de rentabilidad se recomienda Random Forest, acompañado de la fórmula económica y de un intervalo de sensibilidad.

Figura 4.3

Resultados de Random Forest para el margen exportador



4.4 Clasificación del riesgo de margen bajo

Tabla 4.3

Métricas de los modelos de riesgo

Modelo	Exactitud	Precisión	Recall	ROC AUC
Random Forest	0,878	0,757	0,757	0,961
HistGradientBoosting	0,878	0,852	0,622	0,956
Regresión logística	0,878	0,711	0,865	0,965
Prophet	0,857	0,833	0,541	0,926

La regresión logística obtuvo el mayor recall y ROC AUC. Para un sistema de alerta resulta preferible detectar la mayor proporción posible de campañas con margen bajo, aun cuando aumenten algunos falsos positivos; por esa razón se selecciona preliminarmente este modelo. HistGradientBoosting tuvo mayor precisión, pero dejó sin detectar una proporción mayor de casos de riesgo.

Figura 4.4

Comparación de modelos de riesgo de margen bajo





Figura 4.5

Matriz de confusión y curva ROC de la regresión logística



4.5 Síntesis y limitaciones de los resultados

Los resultados preliminares permiten proponer HistGradientBoosting para el precio FOB, Random Forest para el margen y regresión logística para la alerta de riesgo. Esta selección no implica que los modelos estén listos para uso productivo. El desempeño FOB es moderado y requiere validación temporal adicional. El margen objetivo fue construido mediante el precio FOB, un tipo de cambio fijo de S/ 3,75 y costos agrícolas observados, por lo que existe una relación matemática fuerte que favorece a los modelos de margen. Asimismo, la separación de margen fue aleatoria y deberá complementarse con validación por año.

La clase de riesgo representa el 25 % inferior de la distribución del margen y no equivale necesariamente a pérdida monetaria. Prophet se incluye como contraste, pero no es un clasificador nativo y su comparación debe interpretarse con cautela. Finalmente, las métricas evalúan capacidad técnica sobre datos históricos; todavía no demuestran una mejora real en decisiones de productores, aspecto que deberá evaluarse mediante el instrumento y la prueba piloto descritos en el Capítulo II.

REFERENCIAS BIBLIOGRÁFICAS

- Asociación de Exportadores del Perú (2023). Evolución del mercado mundial y nacional de palta. Technical report.
- Capuñay, M., Rivas, I., and Díaz, E. (2025). Hass avocado and profitability in the crisis: A critical look at Peruvian exports (2018–2022). In *Proceedings of the LACCEI International Multi-Conference for Engineering, Education, and Technology*.
- Chen, J., Li, X., and Wang, Y. (2023). A genetic algorithm optimized hybrid model for agricultural price forecasting based on VMD and LSTM network. *Scientific Reports*, 13(1):9932.
- Pantaleón, L., Montes, I., Azañero, R., et al. (2024). Sostenibilidad de las empresas exportadoras de palta en el Perú a nivel internacional (2012–2023). Technical report, Repositorio Alicia CONCYTEC.
- Velásquez, F., Cardona, R., Sierra, S., and Jiménez, E. (2025). Methodological proposal for market risk quantification: A case study of the Hass avocado. *Revista de Economía e Sociología Rural*, 63(2):e234567.
- Xia, C. (2024). Comparative analysis of ARIMA and LSTM models for agricultural product price forecasting. *Highlights in Science, Engineering and Technology*, 85:123–130.
- Zhang, L., Feng, L., and Li, R. (2025). Avocado price prediction using a hybrid deep learning model. arXiv preprint arXiv:2505.09907.

CAPÍTULO A: MATRIZ DE OPERACIONALIZACIÓN DE VARIABLES

Tabla A.1

Matriz de operacionalización de variables

Variable	Definición conceptual	Definición operacional	Dimensión	Indicador	Escala
Sistema predictivo de precios de palta Hass	Solución tecnológica que utiliza datos históricos y algoritmos para estimar precios y producir información de apoyo.	Implementación de modelos de ensamble, regularizados y temporales, integrada con módulos de rentabilidad, escenarios, histórico y reportes.	Predicción	MAE, RMSE, MAPE y R^2 a seis semanas.	Razón
Sistema predictivo de precios de palta Hass			Rentabilidad	Margen y ganancia esperada por escenario.	Razón
Sistema predictivo de precios de palta Hass			Información histórica	Tendencias, estacionalidad, picos, caídas y destinos identificados.	Razón / nominal
Apoyo a la toma de decisiones de siembra	Grado en que la información del sistema facilita comprender alternativas, riesgos y resultados económicos antes de decidir una campaña.	Diferencia entre las respuestas pretest y posttest al utilizar el prototipo.	Comprensión	Puntaje de claridad e interpretación.	Ordinal
Apoyo a la toma de decisiones de siembra			Incertidumbre	Puntaje de seguridad para comparar escenarios.	Ordinal
Apoyo a la toma de decisiones de siembra			Utilidad percibida	Puntaje global del cuestionario.	Ordinal

CAPÍTULO B: MATRIZ DE CONSISTENCIA

Tabla B.1
Matriz de consistencia del proyecto


Elemento	Contenido
Título	Modelo predictivo de precios de palta Hass para decisiones de siembra en La Libertad.
Problema general	¿En qué medida el desarrollo de un modelo predictivo de precios de exportación de palta Hass, integrado con módulos de rentabilidad y análisis histórico, apoyará la toma de decisiones de siembra de productores agrícolas de La Libertad?
Objetivo general	Desarrollar un modelo predictivo de precios de exportación de palta Hass, integrado en una herramienta de apoyo a la toma de decisiones de siembra para productores agrícolas de La Libertad.
Objetivos específicos	Depurar Aduanet e INEI; construir variables temporales y económicas; comparar modelos de regresión, clasificación y pronóstico; desarrollar rentabilidad, escenarios, histórico y reportes; evaluar precisión y utilidad.
Hipótesis general	La solución predictiva integrada mejorará el apoyo a la decisión de siembra al proporcionar pronósticos, escenarios de rentabilidad e información histórica comprensible.
Variables	Independiente: sistema predictivo de precios de palta Hass. Dependiente: apoyo a la toma de decisiones de siembra.
Tipo y diseño	Aplicada, explicativa y predictiva; enfoque cuantitativo; longitudinal; diseño temporal fuera de muestra y evaluación preexperimental pretest–postest.
Población y muestra	Registros disponibles de Aduanet 0804400000 e INEI, con inclusión censal de observaciones válidas; piloto intencional mínimo de 30 usuarios.
Técnicas	Análisis documental, ETL reproducible, modelado temporal, ficha de métricas, encuesta y juicio de expertos.
Análisis	Estadística descriptiva; MAE, RMSE y MAPE; t pareada o Wilcoxon según supuestos; V de Aiken y confiabilidad interna del cuestionario.

CAPÍTULO C: DIAGRAMA DE ISHIKAWA

La Figura C.1 presenta el diagrama de causa y efecto (Ishikawa) que relaciona las causas identificadas con la decisión de siembra de palta Hass en productores de La Libertad.

Figura C.1

Diagrama de Ishikawa: causas de la decisión de siembra sin información anticipada




Nota. Elaboración propia.

CAPÍTULO D: ÁRBOL DE PROBLEMAS

La Figura D.1 representa el árbol de problemas del estudio, articulando el problema central, sus causas y efectos.

Figura D.1

Árbol de problemas: decisión de siembra de palta Hass en La Libertad




Nota. Elaboración propia.

CAPÍTULO E: ÁRBOL DE OBJETIVOS

La Figura E.1 presenta el árbol de objetivos, vinculando el objetivo central con los medios y fines esperados del proyecto.

Figura E.1

Árbol de objetivos: modelo predictivo para apoyo a la decisión de siembra



Nota. Elaboración propia.

CAPÍTULO F: INSTRUMENTOS DE RECOLECCIÓN DE DATOS

F.1 Cuestionario de apoyo a la decisión (pretest y posttest)

Instrucciones: Marque con una X la opción que mejor refleje su opinión sobre la aplicación de apoyo a la decisión de siembra de palta Hass. Escala: 1 = Totalmente en desacuerdo, 5 = Totalmente de acuerdo.

N°	Ítem	1	2	3	4	5
1	Comprendo cómo ha variado históricamente el precio FOB de la palta Hass.					
2	Puedo identificar periodos de mayor y menor precio.					
3	Puedo estimar el margen de una campaña considerando precio, costo y productividad.					
4	Puedo comparar un escenario optimista, esperado y pesimista.					
5	La información disponible reduce mi incertidumbre al evaluar una decisión de siembra.					
6	El pronóstico a seis semanas es comprensible.					
7	La recomendación presentada permite reconocer sus supuestos y riesgos.					
8	La interfaz es comprensible y adecuada para su uso en campo.					
9	Considero útil la herramienta para planificar una campaña.					

Código del participante: _____ **Distrito:** _____ **Rango de hectáreas:** _____

F.2 Ficha de extracción de datos (Aduanet / INEI)

Campo	Descripción / valor registrado
Fuente	Aduanet / INEI / Otra: _____
Periodo	Desde: _____ Hasta: _____
Variable	Valor FOB / Peso neto / Destino / Costos / Producción / Superficie
Unidad de medida	USD/kg, toneladas, etc.
Frecuencia	Mensual / Semanal / Anual
URL o archivo	_____
Observaciones	_____
Fecha de extracción	_____
Responsable	_____

F.3 Consentimiento informado abreviado

Se me ha explicado que participaré en una prueba académica de una herramienta de apoyo a decisiones agrícolas. Mi participación es voluntaria, puedo retirarme en cualquier momento y mis respuestas serán analizadas de manera agregada. Comprendo que la herramienta no garantiza precios ni rentabilidad.

Código: _____ Firma: _____ Fecha: _____

Nota. El cuestionario deberá ser validado por al menos tres jueces y probado con un mínimo de 30 participantes antes de su uso definitivo.

CAPÍTULO G: CONSTANCIA DE APLICACIÓN DE INSTRUMENTOS

CONSTANCIA DE APLICACIÓN DE INSTRUMENTOS

Por medio de la presente, se deja constancia de que los instrumentos de investigación (cuestionario de utilidad percibida y/o ficha de extracción de datos) fueron aplicados en el marco del proyecto de tesis titulado “*Modelo predictivo de precios de exportación de palta Hass para apoyar la toma de decisiones de siembra en productores agrícolas de La Libertad, Perú*”, desarrollado por los estudiantes Peña Serrano Jefferson Miguel y Robles Perez Martin Aryan de la Escuela Profesional de Ingeniería de Sistemas de la Universidad Nacional de Trujillo.

Institución / comunidad:

Lugar y fecha de aplicación:

Número de participantes:

Responsable de la aplicación

Firma y sello

Nota. Formato elaborado para constancia de trabajo de campo. Completar los campos marcados como PLACEHOLDER antes de la sustentación.