

Modelo predictivo de precios de exportación de palta Hass para apoyar la toma de decisiones de siembra en productores agrícolas de La Libertad, Perú

Autores

Peña Serrano Jefferson Miguel

Robles Perez Martin Aryan

Escuela de Ingeniería de Sistemas

Facultad de Ingeniería

Universidad Nacional de Trujillo

Informe de proyecto de investigación

Línea de investigación: Ciencia de Datos e Inteligencia Artificial aplicada a la agricultura

Docente: Ing. Mendoza Rivera Ricardo

Trujillo, Perú

2025

Índice general

1	INTRODUCCIÓN	1
1.1	Contexto mundial de la producción y exportación de palta Hass	1
1.1.1	Importancia económica de la palta Hass	1
1.1.2	Crecimiento del consumo mundial	2
1.1.3	Principales países productores y exportadores	4
1.1.4	Posicionamiento del Perú en el mercado internacional	5
1.2	Problemática de la volatilidad de precios agrícolas	5
1.2.1	Comportamiento variable de los precios agrícolas	5
1.2.2	Influencia de oferta y demanda, clima y estacionalidad	6
1.2.3	Impacto económico en productores y exportadores	7
1.2.4	Riesgo asociado a la toma de decisiones	9
1.3	Situación del sector paltero en Perú y La Libertad	10
1.3.1	Producción y exportación peruana	10
1.3.2	Participación de La Libertad	11
1.3.3	Problemas de planificación de campañas	13
1.3.4	Dependencia de precios históricos y experiencia empírica	14
1.4	Transformación digital y agricultura inteligente	14
1.4.1	Agricultura 4.0	14
1.4.2	Uso de Big Data e Inteligencia Artificial	15
1.4.3	Beneficios de la analítica predictiva para la agricultura	15
1.5	Predicción de precios agrícolas mediante series temporales	16
1.5.1	Modelos estadísticos tradicionales (ARIMA, SARIMA)	16
1.5.2	Modelos de Machine Learning (SVR, Random Forest, XGBoost)	17
1.5.3	Modelos Deep Learning (RNN, LSTM, BiLSTM)	18
1.5.4	Modelos híbridos recientes (ARIMA-LSTM, CNN-LSTM, TCN-MLP-Attention)	19
1.6	Limitaciones de las investigaciones existentes	22
1.6.1	Predicciones orientadas a mercados asiáticos o chinos	22
1.6.2	Pocos estudios para Latinoamérica	22
1.6.3	Escasez de sistemas de apoyo para pequeños productores	22
1.6.4	Ausencia de herramientas móviles orientadas a decisiones de siembra	23
1.7	Necesidad de una solución tecnológica para productores de La Libertad	23
1.7.1	Necesidad de anticipar precios FOB	23
1.7.2	Necesidad de evaluar escenarios de rentabilidad	24
1.7.3	Importancia de disponer de recomendaciones de siembra	24
1.8	Propuesta de investigación	24
1.8.1	Uso de datos de Aduanet e INEI	24
1.8.2	Comparación entre SARIMA, LSTM y SVR	25

1.8.3	Predicción de precios FOB de 4, 6 y 8 semanas	26
1.8.4	Backend en FastAPI	26
1.8.5	Aplicación móvil en React	26
1.8.6	Simulador de rentabilidad y recomendaciones de siembra	27
1.9	Objetivo de la investigación	27
1.10	Hipótesis de investigación	28
1.11	Correspondencia entre objetivos, soluciones e hipótesis	29
2	MÉTODO	30
2.1	Tipo de investigación	30
2.1.1	De acuerdo a la orientación o finalidad	30
2.1.2	De acuerdo a la técnica de contrastación	30
2.2	Nivel de investigación	30
2.3	Diseño de investigación	30
2.4	Población, muestra y muestreo	32
2.4.1	Población	32
2.4.2	Cálculo de muestra para productores	32
2.4.3	Muestra y muestreo por indicador	33
2.4.4	Fuentes de datos	33
2.5	Variables	33
2.6	Técnicas e instrumentos, validación y confiabilidad	34
	Método de análisis de datos	35
	Flujograma para seleccionar la prueba estadística	36
	Contrastación de hipótesis	38
	Síntesis de la metodología estadística	39
2.7	Procedimiento	39

Índice de tablas

1.1	Top 20 principales países productores de palta — Volumen (miles de toneladas métricas)	2
1.2	Evolución de las importaciones de palta por país (volumen en miles TM) . .	4
1.3	Evolución de las exportaciones de palta por país — Valor (millones US\$) .	5
1.4	Estacionalidad de las exportaciones mundiales de palta Hass	7
1.5	Periodos productivos de palta variedad Hass en Chile y Perú	7
1.6	Perú: Superficie cosechada, producción y rendimiento de palta (2015–2019)	10
1.7	Perú: Exportación de palta, principales países de destino (2015–2019) . . .	10
1.8	Perú: Exportaciones de palta por continente (2015–2019)	11
1.9	Perú: Producción de palta por región (2015–2019)	12
1.10	Perú: Valor Bruto de la Producción Agropecuaria por región (2023–2024) .	12
1.11	Comparación SARIMA y LSTM para exportaciones agrícolas (RMSE) . . .	16
1.12	Tabla unificada de rendimiento de modelos de predicción de precios agrícolas	21
1.13	Fuentes de datos: Aduanet e INEI	25
1.14	Variables del modelo predictivo	25
1.15	Product Backlog: funciones principales del software	27
1.16	Objetivos de la solución: Solución Técnica y Tipo Analítica	27
1.17	Correspondencia entre soluciones, hipótesis y objetivos específicos	29
2.1	Interpretación del esquema preexperimental	31
2.2	Etapas del diseño de series temporales	31
2.3	Parámetros para el cálculo de muestra finita	32
2.4	Población, muestra y muestreo por indicador principal	33
2.5	Variables y factores considerados	34
2.6	Técnicas e instrumentos de recolección y análisis	35
2.7	Pruebas estadísticas para la contrastación de hipótesis específicas	38
2.8	Soluciones y algoritmos propuestos	40

Índice de figuras

1.1	Principales frutas tropicales: volúmenes totales de exportación agregados (2016–2025)	3
1.2	Proporciones del volumen de exportación por tipo (USD y toneladas), 2025	3
1.3	Producción mundial de palta en proporción por país	4
1.4	Valores unitarios medios de exportación mundial de aguacate (ene 2023 – jul 2025)	6
1.5	Formación de precios y distribución de ingresos en la cadena de palta . . .	8
1.6	Ingresos totales por venta de palta Hass, año 2024	8
1.7	Precios promedio por kilo de palta Hass en mercado mayorista Lo Valledor, Santiago de Chile, 2021	9
1.8	Aguacate: precios medios al por mayor en EE.UU. (ene 2023 – nov 2025) .	9
1.9	Evolución de producción y exportación de paltas, periodo 2015–2019, Perú	11
1.10	Principales países de destino de paltas peruanas (2015–2019)	13
1.11	Eslabones y actores de la cadena de valor de palta en el valle Torobamba . .	13
1.12	Visualización del modelo SARIMA y comparación con datos reales	16
1.13	Algoritmo de SVR (Support Vector Regression)	17
1.14	Representación esquemática de Random Forest	17
1.15	Procedimiento secuencial en Gradient Boosting Machine (GBM)	18
1.16	Gráfico circular y radar de rendimiento de modelos ML	18
1.17	Arquitectura LSTM (Long Short-Term Memory)	19
1.18	Visualización del modelo LSTM y comparación con datos reales	19
1.19	Taxonomía de técnicas de predicción de precios agrícolas	20
1.20	Evolución de las técnicas de predicción de precios agrícolas	20
1.21	Frecuencia de técnicas y modelos en predicción de precios agrícolas	21
1.22	Arquitectura de la aplicación (diagrama)	26
2.1	Flujograma para seleccionar la prueba estadística en la contrastación de hipótesis	37

CAPÍTULO 1: INTRODUCCIÓN

1.1 Contexto mundial de la producción y exportación de palta Hass

1.1.1 Importancia económica de la palta Hass

La palta Hass (*Persea americana* Mill.) se ha convertido en uno de los rubros agrícolas de mayor valor en el comercio internacional de frutas frescas, impulsada por su perfil nutricional, versatilidad gastronómica y creciente demanda en mercados de Norteamérica, Europa y Asia (Asociación de Exportadores del Perú, 2023; Vittery-Flores and Colchao-Ccahuana, 2023). A diferencia de otros cultivos tradicionales, la palta combina un alto valor unitario con ventanas comerciales diferenciadas según origen geográfico, lo que la convierte en un activo estratégico para economías agrícolas exportadoras. Sierra y Selva Exportadora (2020) documenta que la producción mundial superó las 7 millones de toneladas métricas hacia finales de la década de 2010, con una concentración creciente en variedades de exportación, especialmente Hass.

El peso económico del cultivo se refleja no solo en volúmenes, sino en el valor agregado de la cadena: empaque, certificaciones, logística refrigerada y acceso a mercados premium. Food and Agriculture Organization of the United Nations (2026) señala que la palta encabeza el crecimiento de las frutas tropicales en términos de valor de exportación, superando a productos históricamente dominantes en ciertos segmentos. Para productores y exportadores, la palta Hass representa una fuente de divisas, empleo rural calificado e inversión en infraestructura de riego tecnificado, aunque también expone a los actores locales a dinámicas globales de precios difíciles de anticipar sin herramientas analíticas.

La Tabla 1.1 resume la posición relativa de los principales países productores. México lidera ampliamente el ranking, seguido por República Dominicana y Perú, lo que evidencia una geografía productiva diversa pero con concentración en América Latina y algunos países africanos y asiáticos. Esta distribución condiciona la competencia exportadora y la formación de precios internacionales.

Tabla 1.1

Top 20 principales países productores de palta — Volumen (miles de toneladas métricas)

Rango	País	Volumen (miles TM)
1	México	2.184
2	Rep. Dominicana	644
3	Perú	540
4	Colombia	324
5	Indonesia	304
6	Kenia	239
7	Chile	195
8	Brasil	183
9	Guatemala	168
10	Venezuela	152

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 1.


1.1.2 Crecimiento del consumo mundial

El consumo global de palta ha experimentado un crecimiento sostenido vinculado con tendencias de alimentación saludable, mayor poder adquisitivo en mercados emergentes y popularización del fruto en cadenas de restaurantes y retail (Asociación de Exportadores del Perú, 2023; Zhang et al., 2025). Food and Agriculture Organization of the United Nations (2026) reporta incrementos significativos en volúmenes de importación en Estados Unidos, la Unión Europea y mercados asiáticos, impulsados por campañas de promoción y mayor disponibilidad durante todo el año gracias a la complementariedad estacional entre orígenes.


La Figura 1.1 sitúa a la palta dentro del panorama de frutas tropicales exportadas, evidenciando su dinamismo relativo frente a otros rubros. Paralelamente, la Figura 1.2 muestra la composición del comercio internacional por tipo y unidad de medida, lo cual resulta relevante para comprender cómo el valor y el volumen no evolucionan necesariamente en la misma proporción.

Figura 1.1

Principales frutas tropicales: volúmenes totales de exportación agregados (2016–2025)

**Figura 1.2**

Proporciones del volumen de exportación por tipo (USD y toneladas), 2025



La Tabla 1.2 confirma que los principales mercados importadores concentran la demanda en Norteamérica y Europa, con participación creciente de Asia. Este patrón explica por qué los productores peruanos deben monitorear no solo la oferta local, sino las señales de absorción en destinos clave y la competencia de otros orígenes en las mismas ventanas comerciales.

Tabla 1.2

Evolución de las importaciones de palta por país (volumen en miles TM)

País importador	2015	2016	2017	2018	2019
Estados Unidos	890	920	980	1.050	1.120
Países Bajos	420	445	480	510	545
Francia	180	195	210	225	240
Reino Unido	165	172	185	198	215
Japón	120	128	135	142	155

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 13.

1.1.3 Principales países productores y exportadores

México mantiene el liderazgo productivo y exportador, apoyado en una base instalada consolidada, proximidad al mercado estadounidense y diversificación de destinos (Sierra y Selva Exportadora, 2020). Perú, Chile, Colombia y Kenia han ampliado hectáreas y volúmenes de forma acelerada, incrementando la presión competitiva global. Trincado Gajardo (2022) analiza la complementariedad estacional entre Chile y Perú, subrayando que la superposición parcial de campañas puede generar picos de oferta y presión a la baja sobre precios en determinados meses.

La Figura 1.3 ilustra la proporción de producción mundial por país, visualizando la concentración latinoamericana. En exportaciones, la Tabla 1.3 muestra la evolución del valor en millones de dólares, donde Perú registra el crecimiento más acelerado en el periodo 2015–2019, pasando de participaciones marginales a posicionarse entre los tres primeros exportadores globales.

Figura 1.3

Producción mundial de palta en proporción por país




Tabla 1.3

Evolución de las exportaciones de palta por país — Valor (millones US\$)

País	2015	2016	2017	2018	2019
México	2.450	2.680	2.890	2.720	2.950
Perú	580	720	890	1.120	1.380
Chile	310	340	380	420	460
Colombia	180	210	245	290	320
Kenia	120	145	170	195	230

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 5.

1.1.4 Posicionamiento del Perú en el mercado internacional

El Perú se ha consolidado como exportador estratégico de palta Hass gracias a ventajas agroclimáticas en la costa norte y central, inversión privada en agroexportación y articulación con operadores logísticos especializados (Vittery-Flores and Colchao-Ccahuana, 2023; Pantaleón et al., 2024). Vittery-Flores and Colchao-Ccahuana (2023) sostienen que el país desplazó progresivamente a competidores tradicionales y logró ubicarse entre los principales proveedores globales, con especial protagonismo de la variedad Hass por su resistencia poscosecha y aceptación comercial.

Las exportaciones peruanas mantuvieron tendencia expansiva entre 2021 y 2025, alcanzando volúmenes superiores a 750 mil toneladas y valores FOB por encima de 1.300 millones USD en el último año reportado (PromPerú Exportemos, 2026; Ministerio de Desarrollo Agrario y Riego, 2024). No obstante, Capuñay et al. (2025) advierten que el crecimiento exportador no garantiza rentabilidad uniforme para todos los eslabones de la cadena, especialmente cuando los precios unitarios caen por mayor competencia internacional.

La ventana comercial peruana, concentrada entre marzo y agosto, permite abastecer mercados cuando otros orígenes reducen disponibilidad, pero también expone al sector a riesgos de sobreoferta si las decisiones de siembra no consideran proyecciones de precio. En este contexto, el posicionamiento del Perú como potencia exportadora refuerza la necesidad de herramientas predictivas que traduzcan datos de mercado en señales comprensibles para productores.

1.2 Problemática de la volatilidad de precios agrícolas


1.2.1 Comportamiento variable de los precios agrícolas

Los precios de productos agrícolas de exportación, incluida la palta Hass, exhiben comportamientos variables en el tiempo: tendencias no lineales, ciclos marcados, cambios de régimen y eventos extremos (Velásquez et al., 2025; Zhang et al., 2025). En términos econométricos, muchas series de precios agrícolas son no estacionarias, es decir, presentan media, varianza o estructura de autocorrelación que cambia con el tiempo, lo que dificulta extrapolar tendencias simples sin transformaciones adecuadas (Xia, 2024).

Vittery-Flores and Colchao-Ccahuana (2023) documentaron una caída del precio promedio FOB peruano desde 2.38 USD/kg en 2016 hasta 1.53 USD/kg en 2022, seguida de recuperaciones parciales en años posteriores. Esta trayectoria no responde a un único factor, sino a la interacción entre mayor oferta mundial, competencia internacional, concentración temporal de despachos y variaciones en la demanda de mercados clave. La Figura 1.4 muestra la evolución reciente de valores unitarios medios de exportación mundial de aguacate, evidenciando fluctuaciones mensuales relevantes para la planificación comercial.

Figura 1.4

Valores unitarios medios de exportación mundial de aguacate (ene 2023 – jul 2025)



La volatilidad no se limita al mercado peruano. Trincado Gajardo (2022) analiza precios en el mercado mayorista Lo Valledor (Chile), mientras Food and Agriculture Organization of the United Nations (2026) reporta variaciones en precios al por mayor en Estados Unidos. La comparación entre mercados subraya que los productores enfrentan señales de precio dispersas y, frecuentemente, desactualizadas respecto a las condiciones FOB que determinan su rentabilidad exportadora.

1.2.2 Influencia de oferta y demanda, clima y estacionalidad

La formación del precio FOB sintetiza fuerzas de oferta (hectáreas sembradas, rendimiento, calibres disponibles), demanda (consumo en destino, inventarios, preferencias), estacionalidad (calendarios de cosecha por país) y perturbaciones climáticas (Sierra y Selva Exportadora, 2020; Velásquez et al., 2025). La Tabla 1.4 resume la estacionalidad de exportaciones mundiales, mostrando cómo México, Perú, Chile y Kenia concentran despachos en meses distintos pero parcialmente superpuestos.

Tabla 1.4

Estacionalidad de las exportaciones mundiales de palta Hass

Mes	México (%)	Perú (%)	Chile (%)	Kenia (%)
Ene–Mar	18	2	5	12
Abr–Jun	22	45	15	28
Jul–Sep	35	48	55	35
Oct–Dic	25	5	25	25

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 33. Los porcentajes representan la participación mensual aproximada en el total anual exportado.

Tabla 1.5

Periodos productivos de palta variedad Hass en Chile y Perú

País	Periodo principal de cosecha	Ventana exportadora clave
Chile	Septiembre–Abril	Octubre–Marzo
Perú	Marzo–Agosto	Abril–Julio

Nota. Elaboración propia con base en (Trincado Gajardo, 2022), Cuadro 2.3. La complementariedad estacional entre ambos países condiciona la formación de precios internacionales.

La Tabla 1.5 contrasta los periodos productivos de Chile y Perú, evidenciando una complementariedad parcial que no elimina competencia en transiciones de campaña. Eventos climáticos — sequías, heladas, exceso de lluvias — modifican calendarios de cosecha y calidad de fruta, alterando la relación oferta–precio en semanas críticas (Capuñay et al., 2025). Asimismo, la concentración de exportaciones en pocas semanas puede deprimir precios promedio aun cuando el volumen anual crezca.


Los costos logísticos, el tipo de cambio y los aranceles o barreras fitosanitarias añaden capas de incertidumbre. ComexPerú (2025) señala que la diversificación de mercados es estratégica, pero no neutraliza la volatilidad cuando múltiples orígenes compiten simultáneamente en los mismos destinos. Para el productor, la estacionalidad implica que decisiones de siembra tomadas años vista deben anticipar no solo el clima local, sino la configuración global de oferta en el momento de su primera cosecha comercial.

1.2.3 Impacto económico en productores y exportadores


La volatilidad de precios impacta directamente márgenes de ganancia, capacidad de reinversión y estabilidad financiera de productores y exportadores (Capuñay et al., 2025; Vargas Córdova, 2025). Vargas Córdova (2025) documenta en la cadena de valor del valle Torobamba cómo la distribución desigual de ingresos deja a pequeños productores con menor capacidad de absorber caídas de precio. La Figura 1.5 ilustra esquemáticamente la formación de precios y reparto de ingresos a lo largo de la cadena.

Figura 1.5

Formación de precios y distribución de ingresos en la cadena de palta

**Figura 1.6**

Ingresos totales por venta de palta Hass, año 2024



Cuando el precio FOB cae mientras los costos de insumos, agua, energía y mano de obra aumentan, el productor enfrenta márgenes negativos o break-even precarios. Velásquez et al. (2025) propone métodos de cuantificación de riesgo de mercado aplicados al aguacate Hass, subrayando que la volatilidad no es un evento aislado sino una característica estructural del rubro. Exportadores con contratos y diversificación pueden mitigar parcialmente el riesgo; pequeños productores desvinculados de esquemas contractuales permanecen más expuestos.

Las Figuras 1.7 y 1.8 muestran referencias de precios mayoristas en Chile y Estados Unidos, mercados relevantes para benchmarking. Si bien no equivalen al FOB recibido por el productor peruano, reflejan la sensibilidad de precios spot a cambios de oferta y demanda en ventanas cortas.

Figura 1.7

Precios promedio por kilo de palta Hass en mercado mayorista Lo Valledor, Santiago de Chile, 2021

Coloque la imagen en la carpeta `figuras/`
`figuras/figura2_4.jpg`

Figura 1.8

Aguacate: precios medios al por mayor en EE.UU. (ene 2023 – nov 2025)

Coloque la imagen en la carpeta `figuras/`
`figuras/figura2_5.jpg`

1.2.4 Riesgo asociado a la toma de decisiones

La decisión de siembra de palta Hass implica un horizonte de retorno de mediano y largo plazo: desde la plantación hasta la producción comercial pueden transcurrir cuatro a seis años, periodo durante el cual los precios internacionales pueden variar ampliamente (Vittery-Flores and Colchao-Ccahuana, 2023). Un productor que expande hectáreas bajo precios altos puede enfrentar márgenes reducidos al entrar en producción, especialmente si otros productores tomaron decisiones similares basadas en la misma señal observada.

La dependencia de experiencia empírica y promedios históricos resulta insuficiente cuando la serie presenta quiebres estructurales —como los observados tras la pandemia o ante la entrada acelerada de nuevos orígenes exportadores— (Reis Filho et al., 2022). Sin herramientas predictivas, el productor sobrepondera el último precio observado o relatos locales, incurriendo en sesgos de disponibilidad y subestimación del riesgo de caída.

El riesgo no es solo financiero: incluye sobreinversión en infraestructura de riego,

endeudamiento y presión sobre recursos hídricos en valles ya saturados. Por ello, anticipar escenarios de precio FOB a horizontes de 4, 6 y 8 semanas —útil para decisiones operativas de campaña— y combinarlos con proyecciones de rentabilidad constituye un aporte directo a la gestión del riesgo en La Libertad y regiones palteras afines.

1.3 Situación del sector paltero en Perú y La Libertad

1.3.1 Producción y exportación peruana

El sector paltero peruano ha experimentado una expansión sostenida en superficie, producción y exportaciones durante la última década (Sierra y Selva Exportadora, 2020; Vittery-Flores and Colchao-Ccahuana, 2023). La Tabla 1.6 muestra el incremento de área cosechada, volumen producido y rendimiento promedio entre 2015 y 2019, reflejando tecnificación y maduración de huertos. Paralelamente, las exportaciones crecieron en valor y diversificación de destinos, como indican las Tablas 1.7 y 1.8.

Tabla 1.6

Perú: Superficie cosechada, producción y rendimiento de palta (2015–2019)

Año	Superficie (ha)	Producción (miles TM)	Rendimiento (TM/ha)
2015	28.450	445	15.6
2016	31.200	498	16.0
2017	34.800	562	16.1
2018	38.500	628	16.3
2019	42.100	695	16.5

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 24.

Tabla 1.7

Perú: Exportación de palta, principales países de destino (2015–2019)

Destino	2015	2016	2017	2018	2019
Países Bajos	145	178	210	265	310
Estados Unidos	98	125	155	198	245
España	72	85	98	112	128
Reino Unido	55	62	70	82	95
Chile	42	48	52	58	62

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 28. Valores en millones US\$.

Tabla 1.8

Perú: Exportaciones de palta por continente (2015–2019)


Continente	2015	2016	2017	2018	2019
Europa	285	340	410	495	580
América del Norte	105	132	165	210	258
América del Sur	48	55	62	70	78
Asia	85	102	125	148	175

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 31. Valores en millones US\$.

PromPerú Exportemos (2026) reporta que las exportaciones peruanas de palta fresca superaron los 1.360 millones USD en 2025, con volúmenes cercanos a 770 mil toneladas. Ministerio de Desarrollo Agrario y Riego (2024) confirma la dinámica expansiva incluso en periodos de ajuste climático. La Figura 1.9 sintetiza la relación entre producción y exportación en el periodo 2015–2019, periodo base para comparaciones estructurales del sector.

Figura 1.9

Evolución de producción y exportación de paltas, periodo 2015–2019, Perú



La concentración europea y norteamericana de destinos implica exposición a estándares fitosanitarios exigentes, volatilidad logística y competencia con México y Chile. ComexPerú (2025) enfatiza la necesidad de diversificar mercados sin descuidar la profundización en Países Bajos y Estados Unidos, principales puertas de entrada actuales.

1.3.2 Participación de La Libertad

La Libertad concentra el principal núcleo productivo de palta Hass en el Perú, con participaciones que oscilan entre 32 % y 36 % del volumen nacional según campaña y fuente estadística (Vittery-Flores and Colchao-Ccahuana, 2023; Sierra y Selva Exportadora, 2020). La Tabla 1.9 detalla la evolución de producción por región, donde La Libertad lidera ampliamente sobre Lambayeque, Piura y otras regiones costeras.

Tabla 1.9

Perú: Producción de palta por región (2015–2019)

Región	2015	2016	2017	2018	2019
La Libertad	185	210	245	280	310
Lambayeque	95	105	118	130	142
Piura	72	80	88	95	105
Junín	45	48	52	55	58
Ancash	38	42	46	50	54

Nota. Elaboración propia con base en (Sierra y Selva Exportadora, 2020), Cuadro No. 25. Valores en miles de toneladas métricas.

Tabla 1.10

Perú: Valor Bruto de la Producción Agropecuaria por región (2023–2024)

Región	VBP 2023 (millones S/)	VBP 2024 (millones S/)
La Libertad	8.245	8.620
Lambayeque	4.180	4.350
Piura	3.920	4.105
Ica	6.540	6.890
Lima	2.870	2.950


Nota. Elaboración propia con base en (Ministerio de Desarrollo Agrario y Riego, 2025), Cuadro C.3.

La Tabla 1.10 sitúa el valor bruto de producción agropecuaria regional, evidenciando el peso económico de La Libertad dentro del agro nacional (Ministerio de Desarrollo Agrario y Riego, 2025). Valles como Virú, Moche, Chicama y Chao han impulsado la expansión mediante proyectos de riego, inversión extranjera y experiencia acumulada en agroexportación de arándano, uva y espárrago.

La ventana comercial de La Libertad se alinea con la costa norte peruana (marzo–agosto), sincronizada con picos de despacho en mayo y junio. Esta concentración temporal puede generar cuellos de botella en plantas de empaque y presión sobre precios cuando múltiples fundos cosechan simultáneamente. La Figura 1.10 muestra los principales países de destino de paltas peruanas en el periodo 2015–2019.

Figura 1.10

Principales países de destino de paltas peruanas (2015–2019)


**1.3.3 Problemas de planificación de campañas**

Los productores de La Libertad enfrentan dificultades para planificar campañas ante incertidumbre de precio, variabilidad de calibres demandados y restricciones logísticas (Vargas Córdova, 2025; Capuñay et al., 2025). La planificación empresarial de exportadores —programación naviera, contratos, estandarización de calidad— no siempre se traduce en información oportuna para pequeños y medianos productores que venden a intermediarios o participan parcialmente en esquemas integrados.

Vargas Córdova (2025) identifica en cadenas de valor peruanas asimetrías de información y poder de negociación que perjudican al productor primario. La Figura 1.11 representa eslabones y actores en un valle productivo, ilustrando la complejidad de coordinar decisiones desde la huerta hasta el consumidor final.

Figura 1.11

Eslabones y actores de la cadena de valor de palta en el valle Torobamba



La ausencia de pronósticos accesibles dificulta decidir fechas de cosecha, inversiones en fertilización tardía, contratación de mano de obra y negociación de precios spot. Cuando la campaña se planifica solo con base en el año anterior, se subestima el riesgo de años atípicos

con sobreoferta global o contracción de demanda en Europa.

1.3.4 Dependencia de precios históricos y experiencia empírica

Muchos productores basan decisiones de siembra y manejo agronómico en precios recientes, relatos de vecinos o recomendaciones de intermediarios, métodos que no capturan tendencias, estacionalidad ni choques exógenos (Reis Filho et al., 2022). Vittery-Flores and Colchao-Ccahuana (2023) advierten que mirar exclusivamente el último precio FOB puede inducir prociclicidad: ampliar siembras cuando los precios son altos y contraer cuando ya es tarde para evitar pérdidas estructurales.

La experiencia empírica aporta conocimiento contextual —calidad de suelos, microclimas, calendarios locales— pero no sustituye análisis cuantitativo de series temporales. Theofilou et al. (2025) demuestra en una revisión sistemática que las técnicas predictivas modernas superan en múltiples estudios a métodos basados en promedios móviles simples o extrapolación ingenua.

En La Libertad, la brecha digital agrava la dependencia de señales informales: acceso limitado a dashboards de mercado, reportes técnicos o simuladores de rentabilidad. Cerrar esta brecha requiere traducir modelos estadísticos y de aprendizaje automático en interfaces comprensibles, preferentemente móviles, orientadas a decisiones concretas de siembra y manejo de campaña.

1.4 Transformación digital y agricultura inteligente

1.4.1 Agricultura 4.0

La Agricultura 4.0 integra sensores, conectividad, automatización y analítica de datos para optimizar decisiones en tiempo real (Chen et al., 2023). En cultivos de alto valor como la palta Hass, la digitalización abarca desde monitoreo de suelo y clima hasta trazabilidad postcosecha y analítica comercial. Aunque La Libertad cuenta con fondos tecnificados, persiste una brecha entre grandes exportadores y pequeños productores en adopción de herramientas digitales.

La transformación digital no se limita a la productividad agronómica: incluye la capacidad de procesar información de mercado, simular escenarios económicos y comunicar recomendaciones oportunas. Pantaleón et al. (2024) señala que la sostenibilidad de exportadores peruanos depende cada vez más de gestión de riesgo, cumplimiento normativo y respuesta rápida a señales de demanda, ámbitos donde la analítica de datos aporta ventajas competitivas.

Para productores de palta, Agriculture 4.0 implica combinar datos locales (rendimiento, costos, calendario de cosecha) con datos globales (precios FOB, volúmenes de exportación, tipo de cambio). Sin esta integración, la tecnificación productiva no se traduce necesariamente en mejores decisiones de inversión a mediano plazo.

1.4.2 Uso de Big Data e Inteligencia Artificial

El volumen creciente de datos comerciales, aduaneros y agroclimáticos habilita enfoques de Big Data e Inteligencia Artificial (IA) aplicados a la agricultura (Chen et al., 2023; Murugesan et al., 2022; Reis Filho et al., 2022). Fuentes como Aduanet, INEI, FAOSTAT y bases sectoriales permiten construir series temporales de precio, volumen y destino con granularidad mensual o semanal (UNData, nd).

Chen et al. (2023) demuestran modelos híbridos que combinan descomposición de señales (VMD) con redes LSTM para pronosticar precios agrícolas, superando enfoques univariados tradicionales. Murugesan et al. (2022) comparan arquitecturas LSTM, BiLSTM, CNN-LSTM y ConvLSTM en commodities agrícolas, evidenciando ganancias de precisión cuando se modelan dependencias temporales complejas. Reis Filho et al. (2022) enriquecen series con datos textuales —noticias, reportes— para capturar choques no reflejados inmediatamente en precios históricos.

En el contexto peruano, la IA puede procesar patrones estacionales de exportación peruana, correlaciones con orígenes competidores y rezagos de precio para generar pronósticos FOB. No obstante, la calidad del dato —consistencia aduanera, tratamiento de outliers, alineación temporal— condiciona la utilidad de cualquier modelo avanzado.

1.4.3 Beneficios de la analítica predictiva para la agricultura

La analítica predictiva transforma datos históricos y explicativos en proyecciones accionables: precios esperados, rangos de incertidumbre, escenarios de rentabilidad y alertas tempranas (Theofilou et al., 2025; Xia, 2024). Para productores de palta, los beneficios incluyen mejor timing de decisiones de siembra, reducción de exposición a años de precios deprimidos y mayor transparencia frente a intermediarios.

Xia (2024) comparan ARIMA y LSTM en productos agrícolas, concluyendo que modelos de aprendizaje profundo capturan mejor no linealidades cuando hay suficiente historial. Velásquez et al. (2025) vinculan cuantificación de riesgo con herramientas de apoyo a exportadores, enfoque extensible a productores mediante simuladores simplificados. En la presente investigación se plantean cinco soluciones analíticas —rentabilidad, escenarios, predicción FOB, histórico interactivo y reportes de ciclos— que articulan predicciones con decisiones de negocio.

La clave no es solo predecir con bajo error (RMSE, MAPE), sino comunicar resultados en lenguaje comprensible: “si el precio FOB cae 10 %, el margen proyectado sería X”. Este puente entre modelo y usuario es central en agricultura inteligente orientada a pequeños productores, no solo a analistas de trading agrícola.

1.5 Predicción de precios agrícolas mediante series temporales

1.5.1 Modelos estadísticos tradicionales (ARIMA, SARIMA)

Los modelos autorregresivos integrados de media móvil (ARIMA) y su extensión estacional (SARIMA) constituyen la base clásica del pronóstico de series temporales agrícolas (Xia, 2024; Kurnadipare et al., 2025). ARIMA modela dependencias lineales mediante componentes autorregresivos (AR), integración (I) y media móvil (MA), siendo especialmente útil cuando la serie es estacionaria o puede hacerse estacionaria mediante diferenciación.

SARIMA incorpora estacionalidad explícita, relevante para palta Hass dada la marcada periodicidad de cosechas y exportaciones documentada por Sierra y Selva Exportadora (2020). Kurnadipare et al. (2025) comparan SARIMA con LSTM en exportaciones agrícolas, reportando RMSE competitivos para SARIMA en series con estructura estacional estable. La Tabla 1.11 resume métricas comparativas de referencia.

Tabla 1.11

Comparación SARIMA y LSTM para exportaciones agrícolas (RMSE)

Serie	Modelo	RMSE	MAPE (%)
Exportaciones agrícolas	SARIMA	0.142	8.35
Exportaciones agrícolas	LSTM	0.098	5.72
Precios FOB referencia	SARIMA	0.185	11.20
Precios FOB referencia	LSTM	0.124	7.45

Nota. Elaboración propia con base en (Kurnadipare et al., 2025), Tablas 1 y 3.

La Figura 1.12 ilustra el ajuste de un modelo SARIMA frente a datos reales. Las ventajas de SARIMA incluyen interpretabilidad, bajo costo computacional y madurez metodológica; sus limitaciones aparecen ante quiebres estructurales, no linealidades y volatilidad heterogénea post-pandemia (Velásquez et al., 2025).

Figura 1.12

Visualización del modelo SARIMA y comparación con datos reales


Coloque la imagen en la carpeta `figuras/`
`figuras/figura5_2.jpg`

1.5.2 Modelos de Machine Learning (SVR, Random Forest, XGBoost)

El aprendizaje automático aporta flexibilidad para capturar relaciones no lineales entre precios y variables explicativas: rezagos, volúmenes, indicadores macroeconómicos y estacionalidad codificada (Paul et al., 2022; Theofilou et al., 2025). Support Vector Regression (SVR) proyecta datos a espacios de alta dimensión y encuentra hiperplanos óptimos para regresión, siendo robusto en conjuntos de tamaño moderado (Figura 1.13).

Figura 1.13

Algoritmo de SVR (Support Vector Regression)



Random Forest y XGBoost —ensambles de árboles de decisión y gradient boosting— manejan interacciones entre variables y missing values con menor preprocesamiento que modelos lineales (Paul et al., 2022). La Figura 1.14 esquematiza Random Forest; la Figura 1.15 muestra el procedimiento secuencial de Gradient Boosting Machine (GBM), base conceptual de XGBoost.

Figura 1.14

Representación esquemática de Random Forest





Figura 1.15


Procedimiento secuencial en Gradient Boosting Machine (GBM)



Paul et al. (2022) aplican múltiples algoritmos ML al precio de berenjena (brinjal), encontrando que ensembles superan modelos lineales en MAPE. La Figura 1.16 compara rendimiento relativo mediante gráficos circular y radar. Estos hallazgos son extrapolables con cautela a palta Hass, donde la estacionalidad exportadora y el horizonte FOB requieren validación empírica local.

Figura 1.16


Gráfico circular y radar de rendimiento de modelos ML

**1.5.3 Modelos Deep Learning (RNN, LSTM, BiLSTM)**


Las redes neuronales profundas, especialmente LSTM y BiLSTM, modelan dependencias de largo plazo en series temporales agrícolas (Murugesan et al., 2022; Chen et al., 2023; Zhang et al., 2025). A diferencia de ARIMA, LSTM captura no linealidades y patrones complejos mediante celdas de memoria que retienen información relevante a lo largo de secuencias. La Figura 1.17 presenta la arquitectura LSTM; la Figura 1.18 muestra su desempeño frente a datos reales.

Figura 1.17

Arquitectura LSTM (Long Short-Term Memory)

**Figura 1.18**

Visualización del modelo LSTM y comparación con datos reales



Murugesan et al. (2022) evalúan variantes CNN-LSTM y ConvLSTM, útiles cuando convoluciones extraen patrones locales antes de modelar temporalidad. Zhang et al. (2025) proponen híbridos deep learning para precio de aguacate, combinando extracción de características con capas recurrentes. Kurnadipare et al. (2025) reportan RMSE inferior de LSTM frente a SARIMA en series de exportación, aunque con mayor costo de entrenamiento y necesidad de tuning de hiperparámetros.

BiLSTM procesa secuencias en ambas direcciones temporales, potencialmente útil cuando variables rezagadas y adelantadas aportan señal. No obstante, en pronóstico causal de precios FOB debe evitarse fuga de información futura al conjunto de entrenamiento.

1.5.4 Modelos híbridos recientes (ARIMA-LSTM, CNN-LSTM, TCN-MLP-Attention)

Los modelos híbridos combinan fortalezas de enfoques estadísticos y de aprendizaje profundo: ARIMA-LSTM separa componentes lineales y residuales no lineales; CNN-LSTM extrae patrones locales y dependencias temporales; arquitecturas TCN-MLP-Attention incorporan

convoluciones temporales y mecanismos de atención (Chen et al., 2023; Zhang et al., 2025; Murugesan et al., 2022).

Chen et al. (2023) optimizan híbridos VMD-LSTM con algoritmos genéticos, reduciendo error en commodities agrícolas. Theofilou et al. (2025) documentan en revisiones sistemáticas la proliferación de enfoques híbridos desde 2018, reflejada en las Figuras 1.19 y 1.20.

Figura 1.19

Taxonomía de técnicas de predicción de precios agrícolas





Figura 1.20

Evolución de las técnicas de predicción de precios agrícolas



La Figura 1.21 muestra la frecuencia de técnicas en la literatura reciente; la Tabla 1.12 unifica métricas de desempeño reportadas. Para palta Hass peruana, la selección del modelo debe balancear precisión, estabilidad out-of-sample e interpretabilidad para usuarios finales.

Figura 1.21

Frecuencia de técnicas y modelos en predicción de precios agrícolas


**Tabla 1.12**

Tabla unificada de rendimiento de modelos de predicción de precios agrícolas

Cultivo/Producto	Modelo	RMSE	MAPE (%)	R^2
Palta / aguacate	SARIMA	0.18	9.2	0.82
Palta / aguacate	LSTM	0.12	6.1	0.89
Tomate	Random Forest	0.22	11.5	0.78
Maíz	XGBoost	0.15	7.8	0.85
Brinjal	SVR	0.19	8.9	0.81

Nota. Elaboración propia con base en (Theofilou et al., 2025), Tabla 7. Síntesis de estudios revisados sistemáticamente.

Antecedentes internacionales

Torres (2022) propone mejoras en cadena de suministro de palta peruana mediante series de tiempo, vinculando pronóstico con logística. Zhang et al. (2025) desarrollan modelos híbridos deep learning para precio de aguacate en contextos de mercado asiático. Kurnadipare et al. (2025) y Paul et al. (2022) aportan evidencia comparativa SARIMA/ML/DL en cultivos diversos, aunque con datos y horizontes distintos al FOB peruano.

Xia (2024) y Theofilou et al. (2025) concluyen que no existe un modelo universalmente superior: el desempeño depende de longitud de serie, estacionalidad, frecuencia de muestreo y calidad de variables explicativas. Esta evidencia justifica la comparación empírica de SARIMA, LSTM y SVR sobre datos Aduanet e INEI propuesta en la presente investigación, con horizontes de 4, 6 y 8 semanas alineados a decisiones operativas de campaña.

1.6 Limitaciones de las investigaciones existentes

1.6.1 Predicciones orientadas a mercados asiáticos o chinos

Una proporción significativa de estudios recientes sobre precio de aguacate/palta se orienta a mercados asiáticos o chinos, donde dinámicas de demanda, logística y regulación difieren sustancialmente del contexto peruano (Zhang et al., 2025; Theofilou et al., 2025). Zhang et al. (2025) desarrollan modelos híbridos deep learning con datos y patrones de consumo asiático, cuya transferencia directa a exportadores peruanos requiere recalibración y validación local.

Los mercados asiáticos presentan estacionalidad de importación distinta, preferencias de calibre, esquemas de distribución y sensibilidad a eventos sanitarios que no necesariamente se correlacionan con precios FOB en Rotterdam o Los Ángeles. Aplicar conclusiones de RMSE o MAPE obtenidas en China a productores de La Libertad sin adaptación metodológica puede inducir sobreconfianza o selección inadecuada de modelos.

Además, muchos datasets públicos —como series agregadas de Kaggle— provienen de mercados estadounidenses de retail, no de exportación FOB peruana (Kaggle, nd). La brecha entre precio minorista extranjero y FOB recibido en origen limita la utilidad práctica de modelos entrenados exclusivamente en esas fuentes.

1.6.2 Pocos estudios para Latinoamérica

Theofilou et al. (2025) evidencian en su revisión sistemática una concentración geográfica de estudios en Asia y, en menor medida, India y Europa, con escasez relativa de investigaciones empíricas en Latinoamérica. Trincado Gajardo (2022) aporta evidencia chilena sobre precios hedónicos, y Torres (2022) aborda cadena de suministro peruana, pero pocos trabajos integran predicción FOB, rentabilidad y herramientas de apoyo a productores en un mismo marco.

Perú y La Libertad presentan particularidades —liderazgo productivo nacional, ventana exportadora marzo–agosto, concentración en Países Bajos y EE.UU.— que no están capturadas en modelos calibrados para México o California. Vittery-Flores and Colchao-Ccahuana (2023) caracterizan el contexto peruano, pero no implementan comparación sistemática SARIMA/LSTM/SVR ni despliegan solución software orientada al productor.

Esta vacío metodológico justifica una investigación aplicada que combine datos nacionales (Aduanet, INEI) con modelos comparados y validación orientada a usuarios agrícolas de La Libertad.

1.6.3 Escasez de sistemas de apoyo para pequeños productores

La literatura técnica en predicción de precios agrícolas enfatiza métricas de error y arquitecturas de modelos, pero dedica menos atención a sistemas completos de apoyo a la decisión accesibles para pequeños productores (Vargas Córdova, 2025). Vargas Córdova (2025) documenta asimetrías en cadenas de valor peruanas donde el productor primario captura una fracción minoritaria del valor final, agravada por falta de información de mercado oportuna.

Capuñay et al. (2025) analizan rentabilidad exportadora en crisis, pero desde perspectiva agregada macro, no mediante simuladores personalizables por fondo. Velásquez et al. (2025) proponen cuantificación de riesgo para exportadores, sin traducir outputs a recomendaciones de siembra comprensibles en campo.

Existe, por tanto, una brecha entre avances algorítmicos y herramientas desplegadas que integren pronóstico, simulación de escenarios y cálculo de rentabilidad en interfaces de baja fricción técnica.

1.6.4 Ausencia de herramientas móviles orientadas a decisiones de siembra

Las decisiones de siembra y manejo de campaña ocurren en campo, frecuentemente sin acceso a estaciones de trabajo o dashboards corporativos. Pese al alto penetración de smartphones incluso en zonas rurales productivas, escasean aplicaciones móviles que combinen predicciones FOB, simulador de rentabilidad y recomendaciones explícitas de siembra basadas en escenarios optimista, esperado y pesimista.

La presente investigación propone una arquitectura FastAPI + React desplegable como aplicación móvil, pero la literatura académica revisada por Theofilou et al. (2025) rara vez reporta evaluaciones de usabilidad con productores reales. La ausencia de estudios de adopción móvil en palta Hass peruana representa una oportunidad y una limitación simultánea: hay espacio para innovar, pero pocos antecedentes que guíen diseño de interfaz y métricas de impacto percibido.

La presente investigación busca cerrar esta brecha mediante un sistema integral —backend analítico y frontend móvil— orientado explícitamente a productores agrícolas de La Libertad.

1.7 Necesidad de una solución tecnológica para productores de La Libertad

1.7.1 Necesidad de anticipar precios FOB

Los productores de palta Hass en La Libertad requieren anticipar el precio FOB de exportación para alinear expectativas de ingreso con decisiones de siembra, manejo de campaña y negociación con compradores (Vittery-Flores and Colchao-Ccahuana, 2023; Velásquez et al., 2025). Sin pronósticos a horizontes de 4, 6 y 8 semanas —compatibles con planificación operativa— el productor reacciona ex post a caídas de precio ya materializadas, cuando las acciones correctivas son limitadas.

La predicción FOB constituye el núcleo analítico del sistema propuesto (solución S-3), mediante la comparación de SARIMA, LSTM y SVR sobre datos Aduanet. Kurnadipare et al. (2025) demuestran que modelos bien calibrados superan extrapolaciones ingenuas en series de exportación agrícola, aunque la transferencia a palta peruana exige validación local.

Anticipar precios no elimina la incertidumbre, pero permite cuantificarla: rangos esperados, escenarios adversos y probabilidad implícita de márgenes negativos. Esta información es especialmente valiosa en años de sobreoferta global o cuando múltiples regiones peruanas

concentran cosecha en las mismas semanas (Sierra y Selva Exportadora, 2020; ComexPerú, 2025).

1.7.2 Necesidad de evaluar escenarios de rentabilidad

La rentabilidad de la siembra depende de la interacción entre precio FOB proyectado, rendimiento esperado, costos de producción (agua, fertilizantes, mano de obra, cosecha) y costos logísticos (Capuñay et al., 2025; Vargas Córdova, 2025). Capuñay et al. (2025) muestran que períodos de precios aparentemente favorables pueden ocultar márgenes estrechos cuando los costos unitarios aumentan más rápidamente que los ingresos.

Un simulador de escenarios permite al productor evaluar condiciones optimistas, esperadas y pesimistas variando precio, volumen exportable y costos. La solución S-2 del proyecto traduce predicciones en márgenes proyectados y umbrales de viabilidad económica, cerrando la brecha entre pronóstico técnico y decisión financiera.

Vargas Córdova (2025) evidencia que productores sin herramientas de simulación dependen de estimaciones mentales sesgadas, sobreestimando ingresos en años buenos y subestimando resiliencia necesaria en años malos. La Libertad, por su concentración productiva, amplifica externalidades de decisiones colectivas no coordinadas: muchos productores expandiendo siembra simultáneamente puede deprimir precios futuros para todos.

1.7.3 Importancia de disponer de recomendaciones de siembra

Más allá de gráficos y métricas, el productor necesita recomendaciones accionables: “siembra viable”, “postergar expansión”, “reducir inversión en insumos este ciclo”. Estas recomendaciones deben derivarse de reglas transparentes vinculadas a escenarios simulados, no de cajas negras incomprensibles.

Theofilou et al. (2025) señala que la utilidad percibida de modelos predictivos agrícolas aumenta cuando se combinan con interfaces comprensibles y contexto local. Reis Filho et al. (2022) enfatizan enriquecer series con información textual y explicaciones, enfoque compatible con reportes de ciclos (solución S-5) que identifiquen periodos históricamente favorables o adversos para siembra.

Para La Libertad, disponer de recomendaciones basadas en datos Aduanet e INEI democratiza acceso a inteligencia de mercado antes reservada a exportadores con equipos analíticos. El impacto esperado es mejor alineación entre capacidad productiva regional y señales de demanda global, reduciendo prociclicidad en decisiones de inversión agrícola.

1.8 Propuesta de investigación

1.8.1 Uso de datos de Aduanet e INEI

La investigación utilizará datos de exportación aduanera (Aduanet) e indicadores agropecuarios del INEI para construir series temporales de precio FOB, volumen exportado, destinos y variables de contexto productivo. La Tabla 1.13 resume las fuentes y variables princi-

pales. Aduanet aporta granularidad comercial alineada con la realidad exportadora; INEI complementa con producción regional y valor bruto de producción.

Tabla 1.13

Fuentes de datos: Aduanet e INEI

Fuente	Variables	Descripción
Aduanet	Precio FOB, volumen, destino	Exportaciones aduaneras de palta Hass (partida 080440)
INEI	Producción regional, VBP	Estadísticas agropecuarias por departamento

Nota. Elaboración propia.

El procesamiento incluirá limpieza de registros, tratamiento de valores faltantes, construcción de rezagos, variables estacionales y agregaciones semanales compatibles con horizontes de predicción de 4, 6 y 8 semanas (Reis Filho et al., 2022; Torres, 2022). La calidad del pipeline de datos condiciona directamente la validez comparativa entre SARIMA, LSTM y SVR.

1.8.2 Comparación entre SARIMA, LSTM y SVR

Se implementarán y compararán tres familias de modelos: SARIMA (línea base estadística), LSTM (aprendizaje profundo) y SVR (aprendizaje automático con kernels) (Kurnadipare et al., 2025; Paul et al., 2022; Xia, 2024). La evaluación usará métricas RMSE, MAPE y R^2 sobre particiones temporales out-of-sample, evitando fuga de información futura. La Tabla 1.14 define variables del modelo predictivo.

Tabla 1.14

Variables del modelo predictivo

Variable	Tipo	Descripción
Precio FOB	Dependiente	Precio unitario de exportación (USD/kg)
Volumen exportado	Independiente	Toneladas exportadas por periodo
Mes / temporada	Independiente	Estacionalidad y ventana comercial
Rezago precio	Independiente	Valores rezagados de la serie FOB
Destino principal	Independiente	Concentración por mercado

Nota. Elaboración propia.

La comparación no busca únicamente minimizar error, sino identificar el modelo con mejor equilibrio entre precisión, estabilidad e interpretabilidad para usuarios no técnicos (Theofilou et al., 2025). Referencias como Kurnadipare et al. (2025) y Xia (2024) sugieren

ventajas de LSTM en no linealidades, mientras SARIMA permanece competitivo en series estacionales estables y SVR en conjuntos de tamaño moderado con variables explicativas.

1.8.3 Predicción de precios FOB de 4, 6 y 8 semanas

Los horizontes de 4, 6 y 8 semanas se alinean con decisiones operativas de campaña: programación de cosecha, negociación preliminar, ajuste de insumos y evaluación de viabilidad económica inmediata. Horizontes más largos aumentan incertidumbre; más cortos limitan utilidad para planificación de siembra de mediano plazo. La combinación propuesta cubre necesidades tácticas del productor liberteño.

Las predicciones alimentarán el simulador de escenarios y el módulo de rentabilidad, traduciendo puntos de pronóstico en rangos optimista/esperado/pesimista según bandas de error histórico del modelo seleccionado (Velásquez et al., 2025).


1.8.4 Backend en FastAPI

El backend se desarrollará en FastAPI (Python), exponiendo endpoints REST para entrenamiento/inferencia de modelos, consulta de series históricas, simulación de escenarios y generación de reportes. FastAPI ofrece tipado, documentación automática (OpenAPI) y desempeño adecuado para servicios analíticos que consumirá la aplicación móvil.

La arquitectura separa capa de datos (ETL Aduanet/INEI), capa de modelos (SARIMA, LSTM, SVR) y capa de negocio (rentabilidad, recomendaciones). La Figura 1.22 esquematiza esta arquitectura.

Figura 1.22

Arquitectura de la aplicación (diagrama)



1.8.5 Aplicación móvil en React

El frontend móvil se implementará en React (React Native o React con empaquetado móvil), consumiendo la API FastAPI para mostrar pronósticos, históricos interactivos, simulaciones y recomendaciones de siembra. La interfaz priorizará legibilidad en condiciones de campo: tipografía clara, gráficos simples, lenguaje no técnico y flujos cortos para consultar escenarios.

La Tabla 1.15 resume funciones principales del software según el Product Backlog del proyecto. La evaluación con productores de La Libertad (Capítulo II) medirá utilidad percibida y mejora en comprensión de rentabilidad.

Tabla 1.15

Product Backlog: funciones principales del software

ID	Función	Descripción
F-01	Pronóstico FOB	Predicción de precios a 4, 6 y 8 semanas
F-02	Simulador	Escenarios optimista, esperado y pesimista
F-03	Rentabilidad	Cálculo de ingresos, costos y margen
F-04	Histórico	Visualización de series y tendencias
F-05	Recomendación	Sugerencia de siembra según escenario

Nota. Elaboración propia.

1.8.6 Simulador de rentabilidad y recomendaciones de siembra

El simulador integra predicciones FOB, costos editables por el productor, rendimiento esperado y parámetros logísticos para calcular ingresos, costos totales y margen proyectado (Capuñay et al., 2025). Las recomendaciones de siembra derivan de umbrales configurables: por ejemplo, si el margen esperado en escenario pesimista es negativo, sugerir postergar expansión de hectáreas.

La Tabla 1.16 relaciona soluciones técnicas con tipos analíticos (descriptiva, predictiva, prescriptiva). Las soluciones S-1 a S-5 articulan un sistema integral que va más allá del pronóstico aislado, respondiendo a limitaciones identificadas en la literatura y en la realidad productiva de La Libertad (Vargas Córdova, 2025; Theofilou et al., 2025).

Tabla 1.16

Objetivos de la solución: Solución Técnica y Tipo Analítica

ID	Tipo analítica	Solución técnica
S-1	Descriptiva / predictiva	Módulo de cálculo de rentabilidad
S-2	Prescriptiva	Simulador de escenarios de siembra
S-3	Predictiva	Modelo SARIMA, LSTM y SVR para precios FOB
S-4	Descriptiva	Análisis histórico interactivo
S-5	Descriptiva	Reportes de ciclos productivos

Nota. Elaboración propia.

1.9 Objetivo de la investigación

El objetivo general de la investigación consiste en desarrollar un modelo predictivo de precios de exportación FOB de palta Hass que permita apoyar la toma de decisiones de siembra en productores agrícolas de la región La Libertad, Perú. Este objetivo responde a la necesidad de

transformar datos históricos y variables relevantes del mercado en información anticipatoria útil para decisiones de inversión agrícola de mediano plazo.

Para alcanzarlo, resulta necesario, en primer lugar, caracterizar la evolución histórica del precio FOB de la palta Hass peruana y su relación con la dinámica productiva y exportadora de La Libertad (Vittery-Flores and Colchao-Ccahuana, 2023; Sierra y Selva Exportadora, 2020). En segundo lugar, se requiere identificar y procesar variables explicativas asociadas con oferta, estacionalidad, destinos de exportación y factores externos que puedan mejorar el desempeño predictivo frente a modelos univariados (Reis Filho et al., 2022).

En tercer lugar, corresponde implementar y comparar modelos SARIMA, LSTM y SVR, evaluando su desempeño mediante RMSE, MAPE y R^2 en horizontes de 4, 6 y 8 semanas (Kurnadipare et al., 2025; Xia, 2024). En cuarto lugar, se debe seleccionar el modelo con mejor balance entre precisión, estabilidad e interpretabilidad para el contexto de decisión de siembra. Finalmente, se busca desplegar una aplicación móvil con simulador de rentabilidad y recomendaciones de siembra, de modo que sus resultados se traduzcan en escenarios comprensibles de riesgo, oportunidad y planificación productiva.

1.10 Hipótesis de investigación

La investigación plantea una hipótesis general y cinco hipótesis específicas asociadas con las soluciones funcionales del modelo predictivo. Esta formulación permite vincular el desarrollo tecnológico con indicadores verificables de precisión, utilidad percibida, interpretación de información y apoyo económico a la decisión de siembra.

- **Hg:** El desarrollo de un modelo predictivo de precios de exportación de palta Hass impacta positivamente en el apoyo a la toma de decisiones de siembra en productores agrícolas de La Libertad, Perú, al mejorar la precisión del pronóstico, la evaluación de rentabilidad, la simulación de escenarios, el análisis histórico y la generación de reportes para la planificación agrícola.
- **He1:** El módulo de rentabilidad mejora la estimación económica de la decisión de siembra en productores agrícolas de palta Hass de La Libertad, al permitir calcular ingresos esperados, costos proyectados y margen de ganancia probable.
- **He2:** El simulador de escenarios reduce la incertidumbre en la toma de decisiones de siembra, al permitir evaluar escenarios optimistas, esperados y pesimistas frente a variaciones del precio FOB, volumen exportado y costos de producción.
- **He3:** El modelo predictivo de precios FOB mejora la precisión del pronóstico de precios de exportación de palta Hass, al comparar modelos SARIMA, LSTM y SVR mediante métricas de error como RMSE y MAPE.
- **He4:** El análisis histórico interactivo permite identificar patrones relevantes de comportamiento del precio FOB de la palta Hass, tales como tendencias, estacionalidad, variaciones interanuales y periodos de mayor volatilidad.
- **He5:** Los reportes de ciclos mejoran la interpretación de la información histórica

y predictiva, al facilitar la identificación de periodos favorables o desfavorables para la siembra y planificación productiva.

1.11 Correspondencia entre objetivos, soluciones e hipótesis

Con el fin de mantener coherencia metodológica entre problema, objetivos, soluciones e hipótesis, los objetivos específicos se organizan de acuerdo con las cinco soluciones planteadas para el sistema de apoyo a la decisión. Esta correspondencia permite que cada componente propuesto tenga una finalidad evaluable.

Tabla 1.17

Correspondencia entre soluciones, hipótesis y objetivos específicos

Solución	Hipótesis	Objetivo específico reformulado
S-1: Módulo de rentabilidad	He1	Diseñar e implementar un módulo de rentabilidad que permita estimar ingresos, costos y margen esperado de la siembra de palta Hass en productores agrícolas de La Libertad.
S-2: Simulador de escenarios	He2	Desarrollar un simulador de escenarios que permita evaluar condiciones optimistas, esperadas y pesimistas del precio FOB, costos y volumen exportado para apoyar la decisión de siembra.
S-3: Modelo predictivo de precios FOB	He3	Implementar y comparar modelos SARIMA, LSTM y SVR para pronosticar precios FOB de exportación de palta Hass a 4, 6 y 8 semanas, evaluando su desempeño mediante RMSE y MAPE.
S-4: Análisis histórico interactivo	He4	Construir un módulo de análisis histórico interactivo que permita visualizar tendencias, estacionalidad y comportamiento del precio FOB de la palta Hass.
S-5: Reportes de ciclos	He5	Generar reportes de ciclos productivos y comerciales que faciliten la interpretación de periodos favorables o desfavorables para la planificación de siembra.

Nota. La relación entre objetivos e hipótesis facilita la posterior contrastación estadística y funcional de cada solución propuesta.

CAPÍTULO 2: MÉTODO

2.1 Tipo de investigación

2.1.1 De acuerdo a la orientación o finalidad

Según su orientación o finalidad, la investigación es de tipo **aplicada**, porque utiliza modelos de series de tiempo, aprendizaje automático y analítica de datos para resolver un problema concreto: La incertidumbre de los productores de palta de La Libertad al decidir la siembra sin contar con precios FOB proyectados, escenarios de rentabilidad ni análisis histórico de ciclos de mercado.

2.1.2 De acuerdo a la técnica de contrastación

Según la técnica de contrastación, la investigación es de naturaleza **explicativa y predictiva**, debido a que busca analizar la relación entre variables comerciales y temporales de la palta Hass, y estimar su efecto sobre el precio FOB futuro. La contrastación se realizará comparando el desempeño de algoritmos como SARIMA, LSTM y SVR con variables de rezago mediante métricas de error predictivo.

2.2 Nivel de investigación

La investigación alcanza un nivel **descriptivo, predictivo y prescriptivo**. Es descriptivo porque analiza el comportamiento histórico de precios, volúmenes, temporadas y mercados de la palta Hass. Es predictivo porque estima precios FOB futuros para apoyar decisiones de corto plazo. Es prescriptivo porque traduce el pronóstico en escenarios de decisión, tales como sembrar, mantener, reducir o esperar, considerando costos, productividad y margen esperado.

El análisis tiene enfoque longitudinal, ya que emplea datos históricos ordenados temporalmente. Esta condición permite identificar ciclos, estacionalidad, tendencias y cambios de comportamiento en el mercado de exportación de palta.

2.3 Diseño de investigación

La investigación adopta un diseño aplicado de enfoque mixto, debido a que combina la evaluación técnica de modelos predictivos con la valoración funcional de una herramienta de apoyo a la toma de decisiones de siembra. Para el componente algorítmico se emplea un diseño cuasiexperimental de series temporales, dado que se comparan modelos SARIMA y LSTM sobre una misma serie histórica mensual de precios FOB de palta Hass. Para el componente de evaluación con productores se propone un diseño preexperimental con pretest y posttest en un solo grupo.

El diseño preexperimental se expresa mediante el siguiente esquema:

$$G \longrightarrow O_1 \longrightarrow X \longrightarrow O_2$$

Tabla 2.1

Interpretación del esquema preexperimental

Símbolo	Significado en la investigación
G	Grupo de productores agrícolas de palta Hass de La Libertad seleccionados para el estudio.
O_1	Medición inicial: percepción de utilidad, forma actual de decisión de siembra y estimación de rentabilidad sin apoyo del modelo.
X	Aplicación del sistema propuesto: módulo de rentabilidad, simulador de escenarios, modelo predictivo, análisis histórico y reportes de ciclos.
O_2	Medición final: percepción de utilidad, mejora en estimación de rentabilidad y apoyo percibido en la decisión de siembra después del uso del sistema.

Para la comparación de modelos predictivos se utiliza un diseño de series temporales, debido a que los datos no pueden mezclarse aleatoriamente sin generar fuga de información. En este caso, el orden cronológico de la serie constituye una condición metodológica esencial.

Datos 2018–2026 $\rightarrow$ División 80/20 $\rightarrow$ Entrenamiento $\rightarrow$ Prueba $\rightarrow$ Comparación

Tabla 2.2

Etapas del diseño de series temporales

Etapas	Descripción
Datos históricos	Serie mensual de precios FOB de palta Hass correspondiente al periodo 2018–2026, con 96 registros referenciales.
División temporal	Separación secuencial de 80 % de registros para entrenamiento y 20 % para prueba.
Entrenamiento	Ajuste de modelos SARIMA y LSTM utilizando el bloque histórico inicial.
Prueba	Evaluación con datos posteriores no utilizados durante el entrenamiento.
Comparación	Selección del modelo con mejor desempeño según RMSE y MAPE.

Este diseño resulta pertinente porque permite evaluar dos dimensiones complementarias: la precisión técnica del pronóstico y la utilidad práctica del sistema para productores agrícolas que requieren información anticipatoria antes de decidir una siembra o ampliación del cultivo.

2.4 Población, muestra y muestreo

La investigación considera dos unidades de análisis principales. La primera corresponde a los registros históricos mensuales de precios FOB de exportación de palta Hass, utilizados para entrenar y evaluar los modelos predictivos. La segunda corresponde a los productores agrícolas de palta Hass de la región La Libertad, quienes constituyen la población usuaria del sistema de apoyo a la toma de decisiones de siembra.

2.4.1 Población

Para el indicador de precisión predictiva, la población está conformada por 96 registros mensuales de precios FOB de palta Hass correspondientes al periodo 2018–2026. Esta serie se utiliza para comparar el desempeño de los modelos SARIMA y LSTM mediante las métricas RMSE y MAPE.

Para los indicadores de utilidad percibida y mejora en rentabilidad, la población está conformada por productores agrícolas activos de palta Hass de La Libertad. De manera referencial, y considerando la disponibilidad de información sectorial, se asume una población finita de $N = 400$ productores.

2.4.2 Cálculo de muestra para productores

Para determinar la muestra de productores se emplea la fórmula de poblaciones finitas:

$$n = \frac{NZ^2pq}{E^2(N-1) + Z^2pq}$$

Donde:

Tabla 2.3

Parámetros para el cálculo de muestra finita

Símbolo	Valor	Descripción
N	400	Población referencial de productores.
Z	1.96	Nivel de confianza de 95 %.
E	0.05	Error máximo permitido.
p	0.50	Probabilidad de ocurrencia.
q	0.50	Probabilidad de no ocurrencia.

Reemplazando los valores:

$$n = \frac{400(1,96)^2(0,50)(0,50)}{(0,05)^2(400 - 1) + (1,96)^2(0,50)(0,50)}$$

$$n \approx 196$$

Por tanto, la muestra estimada para la evaluación con productores es de 196 participantes.

2.4.3 Muestra y muestreo por indicador

Tabla 2.4

Población, muestra y muestreo por indicador principal

Indicador	Población	Muestra	Muestreo
Precisión predictiva: RMSE y MAPE	96 registros mensuales de precios FOB, 2018–2026	77 entrenamiento; 19 prueba	Temporal secuencial
Utilidad percibida	400 productores agrícolas activos de palta Hass en La Libertad	196 productores	Estratificado por tamaño de parcela
Mejora en rentabilidad	400 productores agrícolas activos de palta Hass en La Libertad	196 productores	Estratificado por tamaño de parcela

Nota. Para el análisis predictivo se conserva el orden cronológico de los datos, evitando fuga de información entre pasado y futuro. Para utilidad percibida y rentabilidad se propone estratificar por tamaño de parcela, con el fin de representar productores pequeños, medianos y grandes.

2.4.4 Fuentes de datos

De acuerdo con el documento base, se consideran fuentes abiertas y registros nacionales que permiten construir el conjunto de datos inicial: precios FOB, volumen exportado, fecha, destino, temporada y variables económicas asociadas al cultivo. Las fuentes internacionales, como Kaggle y UNData, pueden emplearse como apoyo exploratorio; sin embargo, la aplicación al contexto de La Libertad requiere priorizar registros nacionales de exportación, precios FOB y costos de producción.

2.5 Variables

- **Variable independiente:** modelo predictivo de precios de exportación de palta Hass, implementado mediante algoritmos de series de tiempo y aprendizaje automático.
- **Variable dependiente:** apoyo a la toma de decisiones de siembra, medido a través de la reducción de incertidumbre, claridad del margen esperado y recomendación de escenarios de campaña.

Tabla 2.5

Variables y factores considerados

Variable / factor	Uso dentro del proyecto
Precio FOB	Variable objetivo para el pronóstico mensual o semanal.
Volumen exportado	Factor explicativo de oferta y presión de mercado.
Temporada	Captura patrones de cosecha, estacionalidad y ciclos recurrentes.
Fecha	Permite ordenar la serie temporal y crear rezagos.
Destino o mercado	Ayuda a segmentar comportamiento comercial por demanda.
Costos de producción por kilogramo	Insumo para el cálculo de rentabilidad.
Flete	Componente de costo logístico para estimar margen.
Margen	Indicador económico derivado para apoyar la decisión de siembra.
Hectáreas y productividad	Variables para simular escenarios de campaña.
Ganancia	Resultado económico esperado por escenario.

2.6 Técnicas e instrumentos, validación y confiabilidad

Las técnicas principales serán el análisis documental de fuentes abiertas, el procesamiento de series temporales, el entrenamiento comparativo de modelos y la evaluación funcional de los módulos de apoyo a la decisión.

Tabla 2.6
Técnicas e instrumentos de recolección y análisis

Técnica	Instrumento	Fuente / aplicación
Análisis documental	Ficha de extracción de datos	UNData, Kaggle y fuentes nacionales de exportación.
Procesamiento de datos	Scripts en Python	Limpieza, normalización, rezagos y variables temporales.
Modelado predictivo	SARIMA, LSTM y SVR	Entrenamiento y comparación de modelos.
Evaluación de modelos	MAE, RMSE, MAPE	Medición del error de pronóstico.
Validación funcional	Cuestionario de utilidad percibida	Productores de palta de La Libertad.

Validación y confiabilidad: la calidad de datos será verificada mediante revisión de valores faltantes, duplicados, rangos atípicos y consistencia temporal. La confiabilidad del modelo se evaluará con partición temporal, comparación de métricas y, de ser posible, validación cruzada para series de tiempo. La utilidad del sistema se validará con productores mediante criterios de claridad, pertinencia y facilidad de interpretación.

Método de análisis de datos

El análisis de datos se realizará mediante un flujo de ciencia de datos orientado a series temporales. Primero se depurarán los registros, eliminando duplicados, tratando valores faltantes y verificando consistencia en fechas, precios y volúmenes. Luego se construirán variables temporales como mes, semana, temporada y rezagos del precio FOB, además de variables derivadas para rentabilidad.

Para la evaluación predictiva se utilizarán las siguientes métricas:

- **MAE:** mide el error absoluto promedio del pronóstico.
- **RMSE:** penaliza con mayor fuerza errores grandes.
- **MAPE:** expresa el error porcentual y facilita la interpretación para usuarios no técnicos.


Los modelos se compararán sobre el mismo conjunto de prueba temporal. El modelo seleccionado será aquel que logre el mejor equilibrio entre precisión, estabilidad e interpretabilidad para el productor. Además, los resultados se integrarán con escenarios económicos para estimar margen y ganancia esperada por campaña.

Flujograma para seleccionar la prueba estadística

Para la contrastación de hipótesis se partirá siempre de estadística descriptiva, reportando medidas de tendencia central, dispersión y distribución de los datos. Luego se seleccionará la prueba inferencial según el diseño del estudio, el número de mediciones, la escala de las variables y el supuesto de normalidad. La normalidad se verificará con Shapiro-Wilk cuando $n \leq 50$ y con Kolmogorov-Smirnov cuando $n > 50$.

Figura 2.1

Flujograma para seleccionar la prueba estadística en la contrastación de hipótesis



La elección de la prueba deberá justificarse en el protocolo indicando: Diseño del

estudio, número de grupos o mediciones, escala de la variable, resultado de la prueba de normalidad y criterio aplicado para seleccionar la prueba final.

Contrastación de hipótesis

La contrastación de hipótesis seguirá el criterio metodológico presentado en la Figura 2.1. En primer lugar, se realizará estadística descriptiva para resumir las variables de estudio. En segundo lugar, se verificará la normalidad de los datos mediante Shapiro-Wilk cuando el tamaño muestral sea menor o igual a 50, y mediante Kolmogorov-Smirnov cuando sea mayor a 50. En tercer lugar, se seleccionará la prueba inferencial paramétrica o no paramétrica según la escala de medición, el número de grupos o mediciones y la relación entre muestras.

El nivel de significancia será $\alpha = 0,05$. La hipótesis nula se rechazará cuando el valor p sea menor que 0.05. En caso contrario, no se contará con evidencia estadística suficiente para rechazarla.

Tabla 2.7

Pruebas estadísticas para la contrastación de hipótesis específicas

Hip.	Variables a contrastar	Normalidad y prueba seleccionada	Criterio de rechazo
He1	Estimación de rentabilidad antes y después del módulo de rentabilidad.	Kolmogorov-Smirnov ($n > 50$). t de Student relacionada si existe normalidad; Wilcoxon si no existe normalidad. Estadístico: t o Z .	Rechazar H_0 si $p < 0,05$.
He2	Nivel de incertidumbre percibida antes y después del simulador de escenarios.	Kolmogorov-Smirnov ($n > 50$). t de Student relacionada si existe normalidad; Wilcoxon si no existe normalidad. Estadístico: t o Z .	Rechazar H_0 si $p < 0,05$.
He3	Errores RMSE y MAPE de SARIMA frente a LSTM en el conjunto de prueba.	Shapiro-Wilk si se comparan errores mensuales de prueba ($n \leq 50$). t de Student pareada si existe normalidad; Wilcoxon si no existe normalidad. Estadístico: t o Z .	Rechazar H_0 si $p < 0,05$ y el modelo propuesto presenta menor error.
He4	Nivel de identificación de patrones antes y después del análisis histórico interactivo.	Kolmogorov-Smirnov ($n > 50$). t de Student relacionada si existe normalidad; Wilcoxon si no existe normalidad. Estadístico: t o Z .	Rechazar H_0 si $p < 0,05$.
He5	Nivel de interpretación antes y después de utilizar reportes de ciclos.	Kolmogorov-Smirnov ($n > 50$). t de Student relacionada si existe normalidad; Wilcoxon si no existe normalidad. Estadístico: t o Z .	Rechazar H_0 si $p < 0,05$.

Para las hipótesis vinculadas con productores, la hipótesis nula general indica que no existen diferencias estadísticamente significativas entre las mediciones antes y después de aplicar la solución propuesta. La hipótesis alterna sostiene que sí existen diferencias estadísticamente significativas. Para la comparación SARIMA-LSTM, la hipótesis nula indica que no existen diferencias significativas entre los errores de ambos modelos, mientras que la hipótesis alterna establece que uno de los modelos presenta mejor desempeño predictivo según RMSE y MAPE.

Síntesis de la metodología estadística

El análisis inferencial se aplicará en la sección de resultados con el propósito de validar si las soluciones propuestas generan mejoras estadísticamente significativas. Para el modelo predictivo se compararán los errores de SARIMA y LSTM mediante RMSE y MAPE. Para los módulos orientados al productor se aplicarán mediciones antes y después de usar el sistema, evaluando utilidad percibida, reducción de incertidumbre, mejora en interpretación y estimación de rentabilidad. En todos los casos se reportarán el estadístico de prueba, el valor p , el nivel de significancia y la decisión respecto de cada hipótesis.

2.7 Procedimiento

El procedimiento se organiza siguiendo una adaptación del marco CRISP-DM, debido a que el proyecto combina comprensión del negocio, análisis de datos, modelado y despliegue de una solución de apoyo a la decisión.

- 1. Comprensión del negocio.** Se identifica como objetivo principal reducir el riesgo de pérdida económica por campaña en productores de palta de La Libertad. Para ello, se priorizan tres necesidades: Estimar precios FOB futuros, calcular rentabilidad y generar escenarios de decisión.
- 2. Comprensión de los datos.** Se analizan las fuentes UNData y Kaggle, así como posibles fuentes nacionales de exportación. Se revisan variables como precio promedio, volumen, fecha, región, tipo, destino, temporada y factores comerciales asociados al precio FOB.
- 3. Preparación de los datos.** Se limpian registros inconsistentes, se normalizan variables numéricas, se transforman fechas y se generan variables de rezago. También se construyen variables para escenarios económicos, tales como costo por kilogramo, flete, productividad, margen y ganancia esperada.
- 4. Modelado.** Se evalúan los algoritmos propuestos en el documento base:

Tabla 2.8

Soluciones y algoritmos propuestos

Solución	Tipo de algoritmo	Algoritmos candidatos
S-1: Cálculo de rentabilidad	Regresión no lineal con variables temporales	Random Forest, XGBoost, SVR con rezagos
S-2: Simulador de escenarios	Optimización / prescriptivo	Regresión logística multinomial, XGBoost, árbol CART
S-3: Modelo predictivo de precios FOB	Series de tiempo / deep learning	SARIMA, LSTM, SVR con rezagos
S-4: Análisis histórico interactivo	Analítica descriptiva	Segmentación temporal, filtros por mercado y visualización dinámica
S-5: Reportes de ciclos	Analítica descriptiva	Detección de picos, caídas y comparación anual

- 5. Evaluación.** Se comparan los modelos predictivos mediante MAE, RMSE y MAPE. Además, se evalúa la utilidad de los módulos prescriptivos a partir de la claridad de los escenarios generados y su capacidad para orientar decisiones de campaña.
- 6. Despliegue conceptual.** La solución final se plantea como un sistema de apoyo a la decisión que integra cinco módulos: Cálculo de rentabilidad (S-1), simulador de escenarios (S-2), modelo predictivo de precios FOB (S-3), análisis histórico interactivo (S-4) y generador automático de reportes de ciclos (S-5). Estos módulos permitirán al productor interpretar precios futuros, márgenes esperados y riesgos antes de decidir la siembra.

REFERENCIAS BIBLIOGRÁFICAS

- Asociación de Exportadores del Perú (2023). Evolución del mercado mundial y nacional de palta. Technical report.
- Capuñay, M., Rivas, I., and Díaz, E. (2025). Hass avocado and profitability in the crisis: A critical look at Peruvian exports (2018–2022). In *Proceedings of the LACCEI International Multi-Conference for Engineering, Education, and Technology*.
- Chen, J., Li, X., and Wang, Y. (2023). A genetic algorithm optimized hybrid model for agricultural price forecasting based on VMD and LSTM network. *Scientific Reports*, 13(1):9932.
- ComexPerú (2025). Paltas y diversificación de mercados. <https://www.comexperu.org.pe/articulo/paltas-y-diversificacion-de-mercados>.
- Food and Agriculture Organization of the United Nations (2026). Principales frutas tropicales: resultados 2025. Technical report, FAO, Rome, Italy.
- Kaggle (n.d.). Avocado prices. <https://www.kaggle.com/datasets/neuromusic/avocado-prices>.
- Kurnadipare, N. et al. (2025). Comparative analysis of SARIMA and LSTM for agricultural export forecasting. *[Journal]*.
- Ministerio de Desarrollo Agrario y Riego (2024). Exportación de palta superó las 36 mil toneladas en primer bimestre de 2024. <https://www.gob.pe/institucion/sse/noticias/930071-midagri-exportacion-de-palta-supero-las-36-mil-toneladas-en-primer-bimestre-de-2024>.
- Ministerio de Desarrollo Agrario y Riego (2025). El agro en cifras: diciembre 2024. Technical report, MIDAGRI, Lima, Perú.
- Murugesan, R., Mishra, E., and Krishnan, A. H. (2022). Forecasting agricultural commodities prices using deep learning-based models. *International Journal of Sustainable Agricultural Management and Informatics*, 8(3):242–277.
- Pantaleón, L., Montes, I., Azañero, R., et al. (2024). Sostenibilidad de las empresas exportadoras de palta en el Perú a nivel internacional (2012–2023). Technical report, Repositorio Alicia CONCYTEC.
- Paul, N. et al. (2022). Machine learning for brinjal price prediction. *PLOS ONE*, 17(3):e0265000.
- PromPerú Exportemos (2026). Aguacates (paltas), frescas o secas: subpartida 0804400000. <https://exportemos.pe/descubre-oportunidades-de-exportacion/producto/palta-0804400000>.
- Reis Filho, I. J., Marcacini, R. M., and Rezende, S. O. (2022). On the enrichment of time series with textual data for forecasting agricultural commodity prices. *MethodsX*, 9:101758.

- Sierra y Selva Exportadora (2020). Análisis de mercado de palta 2015–2019. Technical report, Ministerio de Agricultura y Riego del Perú, Lima, Perú.
- Theofilou, A. et al. (2025). A systematic review of agricultural price forecasting techniques. *Sustainability*, 17(1):1–30.
- Torres, A. (2022). Propuesta de mejora de la cadena de suministros de la palta mediante el uso de herramientas de análisis de series de tiempo. Master's thesis, Pontificia Universidad Católica del Perú.
- Trincado Gajardo, N. (2022). Análisis de precios hedónicos de palta hass en Chile. Master's thesis, Universidad [Institución], Chile.
- UNData (n.d.). FAOSTAT agricultural data. <https://data.un.org/Data.aspx?d=FAO&f=itemCode%3A572>.
- Vargas Córdova, N. (2025). Cadena de valor de palta hass en el valle torobamba, ayacucho. Master's thesis, Universidad [Institución], Perú.
- Velásquez, F., Cardona, R., Sierra, S., and Jiménez, E. (2025). Methodological proposal for market risk quantification: A case study of the Hass avocado. *Revista de Economía e Sociología Rural*, 63(2):e234567.
- Vittery-Flores, E. R. and Colchao-Ccahuana, R. (2023). Situación actual y perspectivas de la producción de palta (*Persea americana*) peruana en el contexto del comercio internacional. *Ingeniería Industrial*, 44:157–178.
- Xia, C. (2024). Comparative analysis of ARIMA and LSTM models for agricultural product price forecasting. *Highlights in Science, Engineering and Technology*, 85:123–130.
- Zhang, L., Feng, L., and Li, R. (2025). Avocado price prediction using a hybrid deep learning model. arXiv preprint arXiv:2505.09907.